

# Softwarepraktikum Parallele Numerik WS16/17

Fabian Miltenberger

Karlsruher Institut für Technologie  
E-Mail: fabian.miltenberger@student.kit.edu

Sébastien Thill

Karlsruher Institut für Technologie  
E-Mail: sebastien.thill@student.kit.edu

Thore Mehr

Karlsruher Institut für Technologie

**Zusammenfassung**—Es gibt verschiedene Möglichkeiten, Algorithmen zu parallelisieren. Es gilt, sowohl Hardware als auch Parallelisierungsmethodik sinnvoll auszuwählen. Im Rahmen des Praktikums haben wir den Umgang mit *OpenMP* zur Parallelprogrammierung der CPU kennengelernt. Für die Programmierung auf der Grafikkarte kam *CUDA* zum Einsatz. Bei den parallelisierten Algorithmen handelt es sich um Komponenten zum Lösen der *Finite-Elemente-Methode*.

## Projekt 1 OpenMP

In diesem Projekt lag der Schwerpunkt auf dem Kennenlernen der Bibliothek *OpenMP* sowie deren Handhabung. Weiter ging es um den *Intel Thread Checker*, ein Programm zum Analysieren von Programmcode auf potentielle Fehler in der Parallelisierung. Zu guter letzt haben wir uns mit der FEM-Methode beschäftigt, dabei im Speziellen mit dem Gauß-Seidel-Verfahren zum Lösen linearer Gleichungen wie sie bei der Differenzenmethode vorkommen. Zu guter letzt betrachteten wir einige andere Verfahren zum Lösen solcher Probleme und haben das CG-Verfahren implementiert.

### Aufgabe 1.1 OpenMP

**1.1.a) Hello World.** Wie in der Ausgabe 1 zu sehen, folgt die Reihenfolge der ausgeführten Fäden keinem bestimmten Muster. Auch die Reihenfolge zwischen verschiedenen Ausführungen ist in der Regel verschieden.

```
Hello World, this is Thread0
Hello World, this is Thread5
Hello World, this is Thread4
Hello World, this is Thread7
Hello World, this is Thread1
Hello World, this is Thread3
Hello World, this is Thread6
Hello World, this is Thread2
```

Listing 1. Beispielhafte Ausgabe des Programms bei Ausführung mit 8 Fäden.

**1.1.b) Berechnung von  $\pi$ .** Wie in Tabelle 1 zu sehen, nähert sich der *Speedup* mit zunehmenden  $N$  der Anzahl der Kerne an.

Die manuelle Variante hat eine schlechtere Performance, als die Variante ohne Parallelisierung. Dies lässt sich damit begründen, dass *OpenMP* bei der Variante mit *Reduction* weitere Optimierungen umsetzen kann, beispielsweise kann jeder Thread erst einmal all seine eigenen Beiträge aufsummieren, bevor am Ende nach einer einzigen Synchronisation (anstatt bei jeder Schleifenausführung) die Ergebnisse aller Threads aufsummiert werden.

**1.1.c) Mandelbrot-Menge.** Wie in der Tabelle 2 entnommen werden kann, beträgt die Beschleunigung für 2 Threads etwa 1,4, für 16 Threads etwa 4 und für 32 Threads etwa 8. Dass die Beschleunigung schlechter ist, als bei der Berechnung von  $\pi$ , liegt unserer Meinung nach daran, dass Speicherverwaltung und Caches einen wesentlichen Anteil der Laufzeit ausmachen.

### Aufgabe 1.2 Testtools

#### 1.2.a) Intel Thread Checker.

- 1) Memory read at "demo\_with\_bugs.c":27 conflicts with a prior memory write at "demo\_with\_bugs.c":26 (flow dependence)  
Kann behoben werden, indem die Schleife aufgeteilt wird in zwei Schleifen mit `#pragma omp prallel for simd`.
- 2) Memory read at "demo\_with\_bugs.c":50 conflicts with a prior memory write at "demo\_with\_bugs.c":45 (flow dependence)  
Kann behoben werden, indem das `nowait` statement weggelassen wird.
- 3) Memory read at "demo\_with\_bugs.c":66 conflicts with a prior memory write at "demo\_with\_bugs.c":66 (flow dependence)  
Memory write at "demo\_with\_bugs.c":67 conflicts with a prior memory write at "demo\_with\_bugs.c":66 (anti dependence)  
Kann behoben werden, indem man das `x` als privat markiert, etwa durch Ersetzen des Pragma durch `#pragma omp parallel for private(x)`.
- 4) Vom Thread Checker nicht erkannt.  
Kann behoben werden in dem das Pragma auf `#pragma omp parallel for lastprivate(x)` geändert wird.
- 5) Memory read at "demo\_with\_bugs.c":98 conflicts with a prior memory write at "demo\_with\_bugs.c":98 (flow dependence)  
Memory write at "demo\_with\_bugs.c":98 conflicts with a prior memory write at "demo\_with\_bugs.c":98 (OUTPUT dependence)  
Kann behoben werden in dem das Pragma auf `#pragma omp parallel for reduction(+:sum)` geändert wird.

**1.2.b) Matrixmultiplikation.** Um die Ausnutzung des Caches zu gewährleisten, wird die eine Matrix als Zeilen-, die andere als Spaltenmatrix verarbeitet und nach dem *ikj*-Algorithmus multipliziert. Es wurden eine sequentielle, sowie drei parallelisierte Versionen untersucht. Die parallelisierten Versionen unterscheiden sich wie folgt:

Problemgröße $N$	Seq. Laufzeit	2 Threads		16 Threads		32 Threads		64 Threads	
		Laufzeit	Speedup	Laufzeit	Speedup	Laufzeit	Speedup	Laufzeit	Speedup
$10^7$ critical	0,49	1,02	0,48	39,33	0,012	65,18	0,008	93,21	0,005
$10^7$ reduction	0,29	0,15	1,99	0,044	6,59	0,041	7,07	0,05	5,8
$10^8$ reduction	2,96	1,48	2	0,215	13,78	0,157	18,85	0,185	16
$10^9$ reduction	28,76	14,77	1,95	1,86	15,46	0,99	29,05	1,14	25,25

Tabelle 1: Laufzeiten der Berechnung von  $\pi$  unserer Parallelisierung gegenüber der sequentiellen Version. Getestet wurde auf dem Rechner *i82sn07*. Um Ungenauigkeiten auszugleichen wurden die Zeiten jeweils über 10 (für große Eingaben über 5) Durchläufe gemittelt.

Problemgröße $N$	Seq. Laufzeit	2 Threads		16 Threads		32 Threads	
		Laufzeit	Speedup	Laufzeit	Speedup	Laufzeit	Speedup
1000	6,02	4,35	1,38	1,51	3,99	0,77	7,88
2000	24,65	17,41	1,44	5,92	4,16	3,11	7,92
4000	96,24	70,47	1,37	23,66	4,07	11,913	8,07
8000	394,05	278,34	1,44	94,60	4,16	47,85	8,24

Tabelle 2: Laufzeiten des Mandelbrot Programms unserer Parallelisierung gegenüber der sequentiellen Version. Getestet wurde auf dem Rechner *i82sn07*. Um Ungenauigkeiten auszugleichen wurden die Zeiten jeweils über 10 (für große Eingaben über 5) Durchläufe gemittelt.

- 1) Innerste Schleife mittels *Reduction* parallelisiert
- 2) Mittlere Schleife parallelisiert
- 3) Äußere Schleife parallelisiert

In den Tabellen 3 und 4 wird der Einfluss von Optimierungsoptionen vom GCC und ICC untersucht. Die Messungen wurden auf *i82pc31* ausgeführt, da dieser über eine Intel CPU verfügt. Wie aus den Tabellen abgelesen werden kann, sind die Unterschiede bei den Optimierungsstufen O0 bis O3 gering. GCC scheint etwas schnelleren sequentiellen, ICC hingegen schnelleren parallelen Code zu generieren. Wenn Vektorisierung benutzt werden kann – beim ICC mit der Option *fast* – wird der Code viel schneller, allerdings auf Kosten der Größe, das Binary hat 1,4 MB statt 30 kB. Im Allgemeinen ist das Binary, das vom ICC erzeugt wird, etwa doppelt so groß, wie das, das vom GCC erzeugt wird. Es hat sich allerdings gezeigt, dass die Implementierung der Intel Math Kernel Lib nochmals wesentlich schneller ist, als selbst die Implementierung mit dem ICC und *fast*. Daher lohnt es sich nicht, Löser für Probleme die durch diese Bibliothek abdeckt selbst zu implementieren.

**1.2.c) OpenMP-Profiler ompP.** Anhand der Ausgabe von *ompP* kann leicht gesehen werden, dass wenige der Threads einen Großteil der Arbeit leisten, was bei der Verwendung von *reduction* zu erwarten ist. Durch die explizite Angabe des Scheduling und der Chunksize kann die Arbeit besser verteilt werden. In Tabelle 5 kann der Einfluss der Optionen auf die Laufzeit abgelesen werden.

## Aufgabe 1.3 Parallelisierung

**1.3.a) Begriffe.** Im Folgenden einige bekannte Größen der Parallelisierung, wie sie etwa in der Vorlesung Rechnerstrukturen [14] gelehrt wurden.

Vorab sei  $T(n)$  die Ausführungszeit auf  $n$  Prozessoren,  $P(n)$  die Anzahl der auszuführenden Einheitsoperationen

Der Speedup/die Beschleunigung  $S(n)$ :

$$S(n) = \frac{T(1)}{T(n)} \quad (1)$$

Die Effizienz  $E(n)$ :

$$E(n) = \frac{S(n)}{n} = \frac{T(1)}{n \cdot T(n)} \quad (2)$$

Der Mehraufwand  $R(n)$ :

$$R(n) = \frac{P(n)}{P(1)} \quad (3)$$

Der Parallelindex  $I(n)$ :

$$I(n) = \frac{P(n)}{T(n)} \quad (4)$$

Die Auslastung  $U(n)$ :

$$U(n) = \frac{I(n)}{n} = R(n) \cdot E(n) = \frac{P(n)}{n \cdot T(n)} \quad (5)$$

### 1.3.b) Probleme bei der Parallelisierung.

- **Race Condition**  
Auch bekannt als Wettlaufsituation. Mehrere Fäden greifen lesend und schreibend auf die gleiche Variable zu. Durch den gleichzeitigen Zugriff auf die Variable durch die anderen Fäden hängt das Ergebnis von der konkreten Ausführungsreihenfolge ab. Das Ergebnis kann der Erwartung entsprechen, muss aber nicht. Die Lösung hierfür ist Synchronisation, beispielsweise mittels atomarer Variablenzugriffe oder Barriere. Damit kann sicher gestellt werden, dass kein anderer Faden die Variable manipuliert während ein Faden mit ihr arbeitet.
- **Dead lock**  
Auch bekannt als Verklemmung. Erfordert mindestens zwei Fäden, die gegenseitig auf eine Resource warten, die gerade vom jeweils anderen Faden bereits allokiert wurde (formal: Zyklus im Allokationsgraphen). Damit tatsächlich alle Beteiligten Fäden nicht mehr weiter laufen können, müssen folgende Bedingungen erfüllt sein:

	ICC					GCC			
Optionen	O0	O1	O2	O3	fast	O0	O1	O2	O3
sequentiell	9,26	1,19	1,17	1,17	0,25	9,56	1,16	1,16	1,16
reduction	4,99	1,90	1,88	1,88	1,40	6,06	2,21	2,21	2,21
mittlere	5,88	1,02	1,02	1,02	0,96	6,95	2,55	1,12	1,18
äußere	5,67	0,59	0,59	0,59	0,014	6,02	1,81	0,82	0,82

Tabelle 3: Laufzeiten in Sekunden mit N=1000. Getestet wurde auf dem Rechner *i82pc31*. Um Ungenauigkeiten auszugleichen, wurden die Zeiten jeweils über 10 Durchläufe gemittelt.

	ICC					GCC			
Optionen	O0	O1	O2	O3	fast	O0	O1	O2	O3
sequentiell	74,58	9,9	9,88	9,86	2,27	76,75	9,76	9,75	9,73
reduction	36,67	10,99	10,98	10,95	8,54	43,20	13,76	12,54	12,48
mittlere	47,04	9,01	8,66	8,37	7,95	54,19	30,05	9,60	9,50
äußere	46,50	5,19	4,95	4,92	1,15	44,83	15,07	6,93	6,84

Tabelle 4: Laufzeiten in Sekunden mit N=2000. Getestet wurde auf dem Rechner *i82pc31*. Um Ungenauigkeiten auszugleichen, wurden die Zeiten jeweils über 10 Durchläufe gemittelt.

	auto	Chunks.=1	Chunks.=10	Chunks.=100	Chunks.=1000
N=4000	Maxiter=500				
static	0,99	0,38	0,35	0,89	5,02
dynamic	0,37	0,31	0,30	0,84	5,02
N=8000	Maxiter=500				
static	3,91	1,16	1,15	1,79	13,74
dynamic	1,20	1,08	1,08	1,76	13,74
	auto	Chunks.=1	Chunks.=10	Chunks.=100	Chunks.=1000
N=4000	Maxiter=1000				
static	1,91	0,60	0,54	1,69	9,70
dynamic	0,54	0,51	0,52	1,64	9,70
N=8000	Maxiter=1000				
static	1,97	1,95	2,07	3,44	26,84
dynamic	1,99	1,99	2,00	3,52	26,85

Tabelle 5: Einfluss von Scheduling und Chunksize auf die Laufzeit von Mandelbrot. Getestet wurde auf dem Rechner *i82sn07* mit 32 Threads. Um Ungenauigkeiten auszugleichen wurden die Zeiten jeweils über 10 Durchläufe gemittelt.

- Ressourcen können nicht von außen freigegeben werden
- Fäden können weitere Ressourcen anfordern, und gleichzeitig weiterhin andere halten
- Eine Resource kann immer nur von einem Faden gehalten betreten werden
- Es besteht eine zyklische Abhängigkeit im Allokationsgraphen
- **Bibliotheken**  
Eine Fehlerquelle kann die Verwendung von Bibliotheken in einem parallelen Kontext darstellen, die nicht hierfür konstruiert wurden. Wenn eine Bibliothek beispielsweise von verschiedenen Fäden aus aufgerufen wird, aber intern keine Synchronisationsmechanismen bereithält, kann es auch hier zu Wettlaufsituationen kommen, die jedoch unter Umständen noch schwieriger zu lokalisieren sind. Auch kann es passieren, dass eine geplante Parallelisierung sich aufgrund Synchronisationsmechanismen innerhalb einer Bibliothek nicht wie erwartet umsetzen lässt. In diesem Fall wird die Implementierung der Bibliothek zum Flaschenhals der Parallelisierung. Um solche Fehler zu vermeiden, blockieren manche Bibliotheken Aufrufe, die nicht aus einem bestimmten Faden stammen. Verlassen sollte sich der Entwickler auf solche Mechanismen jedoch nicht. Viele Bibliotheken geben inzwischen in ihrer Dokumentation Hinweise auf den möglichen Einsatz im parallelen Kontext.
- **Messeffekt**  
Wenn man das Debuggen zum Softwareentwurf zählt, so wären als weitere Fehlerquelle auch *Messeffekte* zu nennen. Verbreitete Methoden zum Debuggen, wie etwa die Ausgabe von Information auf der Konsole, können bereits selbst die Ausführung des parallelen Programms beeinflussen, dahingehend, dass die Ausführungsreihenfolge der Fäden, von der das Problem abhängt, beeinflusst wird. So kann es passieren, dass die Mechanismen, die einen Fehler aufspüren sollen, dazu führen, dass dieser nicht weiter auftritt.
- **Cacheeffekte**  
Spielt ebenfalls weniger im Entwurf eine Rolle, als in der Implementierung. Die meisten Prozessoren haben einen eigenen Cache für jeden Rechenkern. Wenn nun verschiedene Fäden auf verschiedenen Kernen gleichzeitig auf der gleichen Variablen arbeiten, so kann es passieren, dass mangels Syn-

chronisation zwischen den Caches der eine Faden die vom anderen Faden verursachte Änderung nicht *sieht*. Lösung hierfür sind spezielle Mechanismen des Prozessors, um Caches bei Bedarf zu Synchronisieren. In C kann man hierfür eine Variable als `volatile` definieren.

**1.3.c) Beschleuniger im Vergleich.** Im Folgenden werden einige parallele Architekturen genauer erläutert. Ein grober Vergleich zur CPU kann Tabelle 6 entnommen werden.

- **CPU**

Die CPU stellt einen großen Instruktionssatz zur Verfügung und kann komplexe Sprünge im Code abarbeiten. Durch Techniken wie Sprungvorhersagen lässt sich in diesen Fällen die Performance steigern und mit Out-of-Order Architekturen erhält man einen hohen Grad an Instruktionslevel-Parallelismus (siehe Vorlesung [14]). Im Allgemeinen finden sich selten mehr als 8 CPU Kerne in einem herkömmlichen Rechner. Es bietet sich die „gewöhnliche“ Programmierung an.

- **GPU**

Nach [18] haben Moderne Rechner fast alle eine GPU verbaut, welche anders als die CPU keine komplexen Befehle abarbeiten kann, sondern durch eine sehr hohe Anzahl an einfachen Rechenkernen massive Parallelität bereitstellen kann. Dieser Beschleuniger arbeitet auf einem Befehlsstrom und führt diesen mehrfach aus (*Single Instruction, Multiple Data* – kurz *SIMD*). Um GPUs für ein eigenes Programm zu nutzen helfen Bibliotheken wie *CUDA* (nVidia spezifisch), oder *OpenCL*.

- **FPGA**

Nach [7] kann ein FPGA Board beliebige Hardware-Eigenschaften bereitstellen, sofern diese vorher auf das FPGA aufgespielt wurden. Im Allgemeinen werden FPGAs zum Testen von Chips, welche sich noch in der Entwicklung befinden, verwendet. Aber das FPGA kann auch als „multifunktionelle“ Beschleunigungskarte eingesetzt werden (lässt sich sehr gut an Anforderungen anpassen). Um ein FPGA zu programmieren bietet sich *OpenCL* an, oder eine der Bibliotheken welche die implementierte Schaltung nutzt.

- **MIC (Intel Many Integrated Core)**

Die Grundidee von MICs ist nach [13], die gewöhnliche x86 CPU Architektur zur Verfügung zu stellen, aber dabei die Parallelität verglichen mit normalen CPUs zu erhöhen. Dies wird durch ein Zusammenschalten von mehreren CPUs auf einem Chip erreicht, welche dann über PCIe mit dem Hostsystem kommunizieren. Es wurde bewusst die x86 Architektur gewählt, damit bekannte Parallelisierungstools wie *OpenMP* oder *OpenCL* genutzt werden können.

Beschleuniger	Parallelität	Anwenderfreundlichkeit
CPU	Niedrig	Gut
GPU	Sehr hoch	Mittel
FPGA	Hoch	Abhängig von Bibliotheken
MIC	(Sehr) hoch	Gut

Tabelle 6: Verschiedene Beschleuniger im Vergleich, die CPU wird als Referenz verwendet.

## Aufgabe 1.4 Gauß-Seidel-Verfahren

**1.4.a) Seriell.** Zu aller erst nehmen wir eine Differenzierung der in der Aufgabenstellung genannten Variablen vor. Unser  $n$  bezeichne dasjenige, welches in der Beschreibung des Gauß-Seidel-Verfahrens auftritt. Das in dem gegebenen Problem genannte  $n$  benennen wir zu  $d$  um. Die restlichen Variablen behalten ihren Namen bei. Sei ein  $l$  für das Verfahren vorgegeben, dann ergeben sich einige andere Größen wie folgt:

$$\begin{aligned} d &= 2^l - 1 \\ h &= \frac{1}{2^l} \\ n &= d^2 \end{aligned} \quad (6)$$

Anschaulich sollen die Werte von  $u_{x,y}$  auf einem  $(d+2) \cdot (d+2)$  großen Gitter berechnet werden. Die Abstände zwischen den Gitterpunkten sei dabei Gitterkonstante  $h$ . Durch die Vorgabe  $u_{x,y} = 0$ , für  $x, y$  auf dem Rand, vereinfacht sich die Problemstellung auf ein Gitter der Größe  $d \cdot d$ , da der Rand implizit als 0 angenommen werden kann. Zum Lösen des Problems geben wir den Gitterpunkten  $u_{x,y}$  eine Ordnung, sodass  $u$  sich als einfacher Spaltenvektor mit  $n = d \cdot d$  Elementen auffassen lässt. Anschaulich sieht diese Ordnung wie folgt aus:

$$u = (u_{1,1} \dots u_{d,1} u_{1,2} \dots u_{d,2} \dots u_{1,d} \dots u_{d,d})^T \quad (7)$$

Der Definitionsbereich von  $u$  (als Funktion aufgefasst) sei  $\mathbb{R}^2$  (ergibt sich aus den gegebenen Randbedingungen). Damit befindet sich ein Gitterpunkt  $u_{x,y}$  an der Position  $(x \cdot h, y \cdot h)$ . Damit berechnen wir den Wert von  $f$  für alle unsere Gitterpunkte, also  $f_{x,y} = f(x \cdot h, y \cdot h)$ . Für diese berechneten Werte von  $f$  nehmen wir die gleiche Ordnung vor wie für  $u$  und können somit  $f$  ebenfalls als einen Spaltenvektor der Größe  $n$  ansehen.

Die Matrix  $A \in \mathbb{R}^{n \times n}$  sei definiert wie vorgegeben und ihre Elemente seien  $(a_{i,j})$ . Wir werden sehen, dass wir zur Lösung  $A$  nicht explizit berechnen und speichern müssen. Nun sind alle Zutaten zur Berechnung von  $u$  in  $Au = h^2 f$  mittels Gauß-Seidel-Verfahren gegeben.

Die Implementierung geht nun Schritt für Schritt vor wie im Algorithmus vorgegeben.  $u^k$  sei  $u$  in der  $k$ -ten Iterierten von  $u$ . Wir beginnen mit  $u^0 = 0$ , wählen also 0 als Startvektor. Dies geschieht der Einfachheit wegen, es hat sich herausgestellt, dass es hierdurch bei keiner der gestellten Aufgaben zu Problemen kommt.

In jeder Iterierten  $k$  soll nun  $u^{k+1}$  berechnet werden. dies geschieht nach der gegebenen Berechnungsvorschrift

$$u_j^{k+1} := \frac{1}{a_{j,j}} (h^2 f_j - \sum_{i=1}^{j-1} a_{j,i} u_i^{k+1} - \sum_{i=j+1}^n a_{j,i} u_i^k) \quad (8)$$

für  $j = 1, \dots, n$ . Es fällt auf, dass für jedes  $u_j$  nur solche  $u_i$  betrachtet werden, die bereits in der gleichen oder vorherigen Iterierten berechnet, und noch nicht überschrieben

wurden. Somit müssen die einzelnen Iterierten  $u^k$  nicht explizit gespeichert werden, tatsächlich reicht hierfür ein Vektor  $u$  aus. Die Berechnungsvorschrift vereinfacht sich zu

$$u_j = \frac{1}{a_{j,j}} (h^2 f_j - \sum_{i=1, i \neq j}^n a_{j,i} u_i) \quad (9)$$

Nach der Definition von  $A$  ist klar, dass  $a_{j,j} = 4$  gilt. Für  $i \neq j$  gilt  $a_{i,j} \in \{0, -1\}$ . Um die dünne Struktur von  $A$  weiter auszunutzen, betrachten wir anschaulich, von welchen Gitterpunkten die Berechnung für einen Gitterpunkt  $(x, y)$  konkret abhängt (genau das wird von  $A$  beschrieben). Dargestellt wird dies in Abbildung 1, wobei  $A$  genau für die vier Nachbarknoten den Wert  $-1$  annimmt, sonst  $0$  (außer für den Knoten selbst). Durch diese Betrachtung zerfällt die Summe der Zuweisung 9 in vier bedingte Additionen, wie in Listing 2 illustriert.

```
double sum = h * h * f[j];

// Linker Nachbarknoten
if (j % d > 0) sum += u[j - 1];

// Rechter Nachbarknoten
if (j % d < d - 1) sum += u[j + 1];

// Oberer Nachbarknoten
if (j / d > 0) sum += u[j - d];

// Unterer Nachbarknoten
if (j / d < d - 1) sum += u[j + d];

u[j] = sum / 4;
```

Listing 2. Ausnutzung der dünnen Struktur von  $A$  zur Berechnung von  $u_j$ . Die Zeilen in  $u$  sind genau  $d$  Elemente lang, daher entspricht bspw.  $j - d$  dem Zugriff auf den oberen Nachbar von  $j$  aus gesehen. Die Bedingungen prüfen genau darauf, ob es sich bei einem Nachbarknoten um einen Randpunkt handelt. Falls ja, so ist keine weitere Betrachtung nötig, da dessen Wert  $0$  ist.

Es wurde gezeigt, wie eine einzelne Iterierte  $k$  von  $u$  sich berechnen lässt. Würde man dies nun immer wiederholen, so würde sich die Lösung  $u$  einem Optimum annähern. Nun haben wir aber eine begrenzte Rechenzeit und müssen daher die Berechnung irgendwann abbrechen, sobald uns das Ergebnis *gut genug* ist. In der Regel kennen wir jedoch die analytische Lösung nicht und wissen daher nicht, wie gut unsere bisherige Lösung ist (sie kann ohnehin durch das Verfahren selbst stark davon abweichen, wie wir in Aufgabe 1.5 sehen werden). Um das Problem zu lösen, brechen wir ab, sobald der *Fortschritt* zwischen zwei Iterationen klein genug ist. Die Annahme hierbei ist, dass sich die Lösung auch durch weitere Iterationen nur noch wenig ändert. Konkret betrachten wir die maximale Veränderung eines Eintrags zwischen den Iterierten  $k$  und  $k + 1$  von  $u$ . Formal  $\maxError := \|u^{k+1} - u^k\|_{\max}$ . Unsere Lösung nehmen wir als gut genug an, sobald  $\maxError < \varepsilon_{Error}$  für eine Schranke  $\varepsilon_{Error}$ . Für unsere Implementierung verwenden wir  $\varepsilon_{Error} = 1 \times 10^{-6}$ , da es einerseits ausreichend klein ist, um in unseren Tests gute Ergebnisse zu liefern, andererseits groß genug, um in absehbarer Zeit berechnet werden zu können.

**1.4.b) Naïv parallel.** Eine naive Parallelisierung des in Aufgabe 1.4.1 implementierten Gauß-Seidel-Verfahrens ist nicht möglich, da innerhalb der Berechnung von  $u^{k+1}$




Abbildung 1. Abhängigkeiten zu Nachbarknoten, um Knoten  $u_{x,y}^{k+1}$  zu berechnen. Es fällt auf, dass zwei Werte der gleichen Iterierten  $k + 1$  benötigt werden (die roten Knoten). Durch diese Abhängigkeit können nicht alle Einträge einer Iterierten gleichzeitig, das heißt parallel, berechnet werden.

– eine naive Parallelisierung würde versuchen genau diese Berechnung zu parallelisieren, also eine einzelne Iterierte – Abhängigkeiten zwischen den Einträgen bestehen. Für die Berechnung von  $u_{x,y}^{i+k}$  werden diese Abhängigkeiten in Abbildung 1 dargestellt. Um etwa  $u_{x,y}^{i+k}$  zu berechnen, werden zu erst die Werte von  $u_{x-1,y}^{i+k}$  und  $u_{x,y-1}^{i+k}$  aus der gleichen Iteration benötigt. Diese wiederum benötigen in gleicher Weise aktuelle Werte von Nachbarknoten.

Eine Mögliche, nicht mehr ganz so naive Lösung, bestünde darin, nun über die Diagonalen zu parallelisieren. Innerhalb der Diagonalen (in  $(1, -1)$  – Richtung) bestehen keine Abhängigkeiten zwischen den Knoten. Dennoch hat sich auch diese Herangehensweise nicht als Vorteilhaft erwiesen. Für jede Iterierte müssten  $d$  Thread-Pools mit maximal  $2d - 1$  Fäden gestartet und synchronisiert werden. Der Synchronisierungsaufwand hierbei scheint um Größenordnungen größer, als die eigentliche Berechnung (in der Vorlesung *Software Engineering für moderne parallele Plattformen* [18] wird diese Herangehensweise auch als *Wavefront* bezeichnet).

**1.4.c) Parallel.** In Aufgabe 1.4.2 haben wir erläutert, dass eine naive Herangehensweise für die Parallelisierung nicht zielführend ist. Insbesondere haben wir hierfür die zahlreichen Abhängigkeiten innerhalb der Berechnung einer Iterierten verantwortlich gemacht. Um also das Gauß-Seidel-Verfahren nun doch effizient zu parallelisieren, ist eine übergeordnete Betrachtung des Problems von Nöten.

Die Idee hinter unserer Lösung besteht darin, in einem parallelisierbaren Schritt Einträge von  $u$  für verschiedene Iterierte  $k$  der sequentiellen Variante zu berechnen. Wie in Abbildung 1 zu sehen, hängt die Berechnung eines Knotens von den *aktuellen* Werten des linken und des oberen Nachbarn ab. Diese müssen also schon vorher

$u_{1,1}^{k+1}$	$u_{2,1}^{k+1}$	$u_{3,1}^k$	$u_{4,1}^k$	$u_{5,1}^{k-1}$	$u_{6,1}^{k-1}$	$u_{7,1}^{k-2}$
$u_{1,2}^{k+1}$	$u_{2,2}^k$	$u_{3,2}^k$	$u_{4,2}^{k-1}$	$u_{5,2}^{k-1}$	$u_{6,2}^{k-2}$	$u_{7,2}^{k-2}$
$u_{1,3}^k$	$u_{2,3}^k$	$u_{3,3}^{k-1}$	$u_{4,3}^{k-1}$	$u_{5,3}^{k-2}$	$u_{6,3}^{k-2}$	$u_{7,3}^{k-3}$
$u_{1,4}^k$	$u_{2,4}^{k-1}$	$u_{3,4}^{k-1}$	$u_{4,4}^{k-2}$	$u_{5,4}^{k-2}$	$u_{6,4}^{k-3}$	$u_{7,4}^{k-3}$
$u_{1,5}^{k-1}$	$u_{2,5}^{k-1}$	$u_{3,5}^{k-2}$	$u_{4,5}^{k-2}$	$u_{5,5}^{k-3}$	$u_{6,5}^{k-3}$	$u_{7,5}^{k-4}$
$u_{1,6}^{k-1}$	$u_{2,6}^{k-2}$	$u_{3,6}^{k-2}$	$u_{4,6}^{k-3}$	$u_{5,6}^{k-3}$	$u_{6,6}^{k-4}$	$u_{7,6}^{k-4}$
$u_{1,7}^{k-2}$	$u_{2,7}^{k-2}$	$u_{3,7}^{k-3}$	$u_{4,7}^{k-3}$	$u_{5,7}^{k-4}$	$u_{6,7}^{k-4}$	$u_{7,7}^{k-5}$

Abbildung 2. Verdeutlichung der Vorgehensweise der Parallelisierung. Zuerst werden diejenigen Einträge von  $u$  parallel berechnet, die sich in grau Markierten Feldern befinden. Anschließend parallel die Einträge in den weißen Feldern. Es ist zu beachten, dass die Einträge  $u_{x,y}$  für unterschiedliche Iterierte  $k$  berechnet werden.

berechnet worden sein. Hieraus ergibt sich eine Reihenfolge, in der die Knoten berechnet werden müssen, nämlich von links oben nach rechts unten (in unserer Lösung zu 1.4.2 haben wir die dabei auftretenden, parallelisierbaren Diagonalen bereits erwähnt). Diese Reihenfolge können wir beibehalten, wenn wir für jede Diagonale eine andere Iterierte berechnen.

Angenommen wir berechnen links oben  $u_{1,1}^{k+1}$ , dann können wir parallel dazu auch  $u_{3,1}^k$ ,  $u_{2,2}^k$  und  $u_{1,3}^k$  berechnen (sowie auch alle weiteren Diagonalen mit je 2 Abstand). Im nächsten Schritt können wir dann alle nun noch nicht abgedeckten Diagonalen gleichzeitig berechnen. In Abbildung 2 sind all diese Diagonalen noch einmal aufgetragen. Die Felder, über die gleichzeitig berechnet werden kann, bilden ein Schachbrettmuster.

Der Grund, weshalb immer eine Diagonale ausgelassen werden muss, liegt in den vorhandenen Datenabhängigkeiten (dieses Mal in die andere Richtung, also zu den Nachbarn rechts und unten). Angenommen, man möchte  $u_{1,1}^{k+1}$  und  $u_{2,1}^k$  parallel berechnen, dann würde man bereits für ersteren den Wert von letzterem benötigen (gemäß Abbildung 1). Lässt man jedoch eine Diagonale frei, beispielhaft zwischen  $u_{1,1}^{k+1}$  und  $u_{3,1}^k$ , so konnte man  $u_{2,1}^k$  bereits vorher berechnen. Im nächsten Schritt (das heißt nach Synchronisierung) kann aus den berechneten  $u_{1,1}^{k+1}$  und  $u_{3,1}^k$  das dazwischen liegende  $u_{2,1}^{k+1}$  berechnet werden usw.

Durch diese Schachbrett-artige Parallelisierung hat ein Berechnungsschritt die Gestalt:

- 1) Berechne parallel über alle schwarzen Felder
- 2) Berechne parallel über alle weißen Felder

Es sei nicht zu verschweigen, dass hier im Gegensatz zur seriellen Variante sehr wohl mehrere  $u$  gleichzeitig zu speichern sind. Sobald in einem Berechnungsschritt das

Feld ganz rechts unten, also  $u_{d,d}^{k+2-d}$ , berechnet wurde, müssen im Falle des Abbruchs (weil das Abbruchkriterium aus 1.4.1 erfüllt ist), alle  $u_{x,y}^{k+2-d}$  noch immer bekannt sein, um  $u_{x,y}^{k+2-d}$  als Ergebnis ausgeben zu können. Ebenso muss das Abbruchkriterium stets auf den Werten der gleichen Iterierten arbeiten, um exakt das gleiche Resultat wie die serielle Variante zu erhalten.

In jedem Berechnungsschritt wird genau eine Iterierte des Verfahrens berechnet. Allerdings gilt dies erst, sobald  $d - 1$  Schritte ausgeführt wurden, denn erst dann ist schließlich der Eintrag rechts unten  $u_{d,d}^{k+2-d} = u_{d,d}^1$  berechnet (die *Historie* muss erst gefüllt werden). So kommt es, dass die parallele Version bei gleichen Eingaben exakt die gleichen Ergebnisse wie die serielle Version ausgibt, jedoch dabei genau  $d - 1$  Iterationen mehr benötigt. Wie der Tabelle 7 zu entnehmen, ist die parallele Version mit 32 Kernen bei großer Problemgröße ( $l = 9$ ) mit einem *Speedup* von 7,57 aber immerhin noch deutlich schneller. Die eher geringe Effizienz schreiben wir dem Synchronisationsaufwand sowie den eher Cache-unfreundlichen Speicherzugriffen zu.

Aufgrund des benötigten Speichers der Historie von  $u$  (etwa 8 GB) konnten wir für  $l$  größer als 9 keine Tests durchführen.

## Aufgabe 1.5 Partielle Differentialgleichungen

**1.5.a) Bedingungen.** Die Bedingungen lauten nach den Folien der FEM-Einführung:

- $\Omega$  sei ein beschränktes Gebiet
- $\Gamma$  sei hinreichend glatt
- $f : \Omega \rightarrow \mathbb{R}$  gegebene Funktion, wie es hier der Fall ist.

**1.5.b) Laplace-Operator anwenden.** Gesucht ist  $f$  mit

$$u(x, y) = \sin(2M\pi x) \sin(2N\pi y) \quad (10)$$

Dies kann durch einfache Anwendung des *Laplace-Operators*  $\Delta$  berechnet werden:

$$\begin{aligned}
 f(x, y) &= -\Delta u(x, y) \\
 &= -\frac{\partial^2 u}{\partial x^2} - \frac{\partial^2 u}{\partial y^2} \\
 &= -\frac{\partial}{\partial x} (2M\pi \cos(2M\pi x) \sin(2N\pi y)) \\
 &\quad - \frac{\partial}{\partial y} (2N\pi \sin(2M\pi x) \cos(2N\pi y)) \\
 &= 4M^2\pi^2 \sin(2M\pi x) \sin(2N\pi y) \\
 &\quad + 4N^2\pi^2 \sin(2M\pi x) \sin(2N\pi y) \\
 &= (M^2 + N^2)4\pi^2 \sin(2M\pi x) \sin(2N\pi y)
 \end{aligned} \quad (11)$$

**1.5.c) Lösung mittels GSV.** Da in Gleichung 11  $M, N \in \mathbb{N}$  beliebig, wählen wir der Einfachheit halber  $M = N = 1$  zur Lösung dieser Teilaufgabe. Damit ergibt sich

$$f(x, y) = 8\pi^2 \sin(2\pi x) \sin(2\pi y) \quad (12)$$

Die dazugehörige analytische Lösung ist dann nach Aufgabenstellung gegeben als

$$u(x, y) = \sin(2\pi x) \sin(2\pi y) \quad (13)$$



Problemgröße			Seq.	2 Threads		4 Threads		...	32 Threads	
$l$	$d$	$n$	Laufzeit	Laufzeit	Speedup	Laufzeit	Speedup	...	Laufzeit	Speedup
4	15	225	0,005	0,007	0,357	0,008	0,625	...	1,361	0,0389
5	31	961	0,053	0,056	0,473	0,049	1,08	...	4,041	0,178
8	255	65.025	115	81	1,42	45,3	2,54	...	25,33	4,54
9	511	261.121	1340	943	1,42	504	2,67	...	177	7,57

Tabelle 7: Laufzeiten unserer Parallelisierung gegenüber der sequentiellen Version. Getestet wurde auf dem Rechner *i82sn07*. Um Ungenauigkeiten auszugleichen wurden die Zeiten jeweils über 100 (für große Eingaben über 10) Durchläufe gemittelt.

$l$	2	3	4	8	9
$d$	3	7	15	255	511
$h$	0,25	0,125	0,0625	0,00391	0,00195
Max. Fehler	0,234	0,053	0,0130	0,00174	0,0266
Iterationen	21	64	175	11043	98558

Tabelle 8: Maximaler Fehler und Anzahl der durchgeführten Operationen in Abhängigkeit von  $l$  bzw. Gitterkonstante  $h$ .

und wird verwendet um den maximalen Fehler der Näherung zu berechnen.

Das  $f$  auf Gleichung 12 kann einfach in den Code der vorangegangenen Aufgabe eingesetzt werden. Wie auch [9] entnommen werden kann, lässt sich das Problem mit dem in Aufgabe 1.4.1 gelösten Problem lösen. Es ergeben sich die in Abbildung 3 gezeigten Näherungen. Mit zunehmendem  $l$  bzw. abnehmender Gitterkonstante  $h$  werden die Lösungen nicht nur feiner, sondern der maximale Fehler zur analytischen Lösung von  $u$  auch kleiner wird. Ab  $l = 8$  wird der Fehler allerdings wieder größer, wie Tabelle 8 entnommen werden kann. An dieser Stelle scheint das für das Abbruchkriterium gewählte  $\varepsilon_{Error}$  aus Aufgabe 1.4.1 zu grob gewählt zu sein, denn eine weitere Verfeinerung dessen reduzierte den Fehler der Näherung (nur) für große  $l$  deutlich (was die Frage aufwirft, ob man  $\varepsilon_{Error}$  abhängig von  $l$  wählen sollte).

Das verwendete Vorgehen wird als  $h$ -FEM bezeichnet, da wir lediglich die Gitterkonstante  $h$  anpassen. Eine  $p$ -FEM- oder gar  $hp$ -FEM-Methodik würde den Grad des zum Abtasten verwendeten Polynoms erhöhen.

## Aufgabe 1.6 Partielle Differentialgleichungen

**1.6.a) Verfahren.** Alphabetische Liste gängiger Krylow-Unterraum-Verfahren (nach [4]):

- Arnoldi-Verfahren, zur Eigenwertapproximation
- BiCG, das CG-Verfahren für nicht SPD-Matrizen
- BiCGSTAB, Stabilisierung von CGS
- BiCGSTAB(ell), Stabilisierung von CGS
- BiCGSTABTFQMR, der Ansatz hinter TFQMR angewandt auf BiCGSTAB
- BiOres, eine Variante des BiCG-Verfahrens
- BiOmin, eine Variante des BiCG-Verfahrens
- BiOdir, eine Variante des BiCG-Verfahrens
- CG, zur approximativen Lösung linearer Gleichungssysteme
- CGNE, CG-Verfahren auf den Normalgleichungen, Variante 1
- CGNR, CG-Verfahren auf den Normalgleichungen, Variante 2




Abbildung 3. Näherungsweise Lösung für  $u$ , berechnet mittels Gauß-Seidel-Verfahren. Von oben nach unten:  $l = 3, l = 4, l = 5$  bzw.  $h = \frac{1}{8}, h = \frac{1}{16}, h = \frac{1}{32}$ . Geplottet mittels GNU Octave.

- CGS-Verfahren, quadrierte BiCG-Rekursion
- FOM, zur approximativen Lösung linearer Gleichungssysteme
- GMRES, zur approximativen Lösung linearer Gleichungssysteme
- Hessenberg-Verfahren, zur Eigenwertapproximation
- Lanczos-Verfahren, zur Eigenwertapproximation
- MinRes, zur approximativen Lösung linearer Gleichungssysteme
- Orthores, Orthomin und Orthodir, Verallgemeinerungen des CG-Verfahrens
- Ores, eine Variante des CG-Verfahrens
- Omin, eine Variante des CG-Verfahrens
- Odir, eine Variante des CG-Verfahrens
- Potenzmethode, älteste Methode zur Eigenwertapproximation
- QMR, zur approximativen Lösung linearer Gleichungssysteme
- Richardson-Iteration, bei geeigneter Interpretation
- SymmLQ, zur approximativen Lösung linearer Gleichungssysteme
- TFQMR, zur approximativen Lösung linearer Gleichungssysteme

Die häufig verwendeten Grundverfahren sind: CG-Verfahren, GMRES und Lanczos-Verfahren

**CG-Verfahren:** Hierbei handelt es sich um einen iterativen Algorithmus und ist gedacht für große lineare, symmetrische, positiv definite und dünn besetzte Gleichungssysteme. Das CG-Verfahren liefert nach spätestens  $n$  (Dimension der Matrix) Schritten die exakte Lösung.

**GMRES:** Ein iteratives Verfahren welches sich besonders für große, dünn besetzte lineare Gleichungssysteme eignet. GMRES kann und wird für nicht-symmetrische Matrizen eingesetzt, allerdings wird die exakte Lösung erst nach endlich vielen Schritten geliefert.

**Lanczos-Verfahren:** Ebenfalls ein iterativer Algorithmus, welcher Eigenwerte mit den entsprechenden Eigenvektoren bestimmen kann, als auch lineare Gleichungssysteme lösen. Die Konvergenz vom Algorithmus ist von den Eigenwerten abhängig.

Bei der Auswahl von diesen drei Verfahren für unser Problem, eignet sich das CG-Verfahren am besten, da die vom Problem gegebene Matrix alle Kriterien erfüllt. Des weiteren ist die Konvergenz  $n$  (nach [19]) von Vorteil, da wir davon ausgehen können, dass wir schon viel früher eine Lösung erreicht haben werden welche unter einer gewissen Toleranz *gut genug* sein wird. Gegen GMRES spricht nur die möglicherweise langsamere Konvergenz und die hier nicht benötigte Flexibilität auch nicht-symmetrische Matrizen bearbeiten zu können. Das Lanczos-Verfahren wäre eine Alternative, vor allem da die Eigenwerte und somit die Konvergenz im Voraus bekannt sind.

Unsere Parallelisierung arbeitet auf der Ebene der Vektoreinträge, da diese zu großen Teilen unabhängig von einander berechnet werden können (ganz im Gegensatz zum Gauß-Seidel-Verfahren aus 1.4). Auch hier kann die dünne Struktur von  $A$  dahingehend ausgenutzt werden, dass Berechnungen der Art  $A \cdot x$  im Algorithmus für jeden Eintrag im Ergebnisvektor zu vier bedingten Additionen

zerfallen. Auch hier muss  $A$  daher nicht explizit gespeichert oder berechnet werden.

Der *Intel Thread Checker* gibt für unser Programm Folgendes aus:

- Thread termination at "**cg\_parallel.c**":31 - includes stack allocation of 2,004 MB and use of 4,793 KB
- Thread termination at "**cg\_parallel.c**":31 - includes stack allocation of 68 KB and use of 3,246 KB
- Thread termination at "**cg\_parallel.c**":100 - includes stack allocation of 8 MB and use of 127,168 KB

**1.6.b) CG-Verfahren.** Unsere parallele Version des CG-Verfahrens konnte gegenüber dem Gauß-Seidel-Verfahren das Problem aus Aufgabe 1.5 bis zu 40-mal so schnell lösen. Eine Übersicht über den *Speedup* sowie die *Efficiency* ist in Tabelle 9 zu finden.

Wie auch unsere Implementierung des Gauß-Seidel-Verfahrens aus Aufgabe 1.4, nutzen wir hier für unsere Implementierung die dünne Struktur der Matrix  $A$  aus. Eine Vorkonditionierung würde diese Struktur beeinträchtigen, im Rahmen des Praktikums haben wir jedoch gelernt, dass es möglich ist, die Vorkonditionierung so zu wählen, dass dies kein Problem für den Rechenaufwand des eigentlichen Verfahrens darstellt. Das Problem wäre jedoch, dass die Vorkonditionierung selbst rechenaufwändig wäre. Wenn sie wie hier nicht wieder verwendet wird, ist zu erwarten, dass sich ihre aufwändige Berechnung nicht lohnt.

**1.6.c) Bibliotheken.** In Tabelle 10 haben wir drei Bibliotheken zur Anwendung der Finiten Elemente Methode aufgelistet und verglichen. Weitere Bibliotheken, die es nicht in die Tabelle geschafft haben, wären beispielsweise *Feel++*[2] und *Libmesh*[5].

Im Rahmen dieses Praktikums würde sich, zumindest für Projekt 1, *HiFlow*<sup>3</sup> gut eignen, da hier eine ausgereifte OpenMP Funktionalität gegeben zu sein scheint, die den Portierungsaufwand stark verringert.



Problemgröße			Seq.	2 Threads		...	16 Threads		32 Threads	
$l$	$d$	$n$	Speedup	Speedup	Efficiency	...	Speedup	Efficiency	Speedup	Efficiency
4	15	225	1,74	1,81	0,906	...	2,44	0,153	2,93	0,0917
5	31	961	4,01	3,71	1,86	...	1,44	0,0898	3,46	0,109
8	255	65.025	17,9	16,5	8,27	...	16,8	1,05	4,05	0,127
9	511	261.121	27,6	25,9	12,9	...	39,5	2,47	37,9	1,18

Tabelle 9: *Speedup* und *Efficiency* für das CG-Verfahren gegenüber dem Gauß-Seidel-Verfahren für das Problem aus Aufgabe 1.5. Die zugrunde liegenden Laufzeiten wurden anhand des Rechners *i82sn07* ermittelt.

Bibliothek	Unterschiede	Gemeinsamkeiten
HiFlow <sup>3</sup> [3]	MPI und OpenMP basiert, Hohe Parallelität (von Laptop bis zu Cluster), Keine externen Bibliotheken benötigt (optional Libraries, unter anderem OpenMP)	Für C++ gedacht, Implementieren Krylov-Unterraumverfahren, Diskretisierung wählbar
MFEM[6]	MPI basiert (und experimenteller OpenMP Support), Sehr hohe Parallelität (mehrere hunderttausend Kerne), Keine externen Bibliotheken benötigt	
Deal.II[1]	MPI basiert, Hohe Parallelität (16000 Kerne mindestens), Keine externen Bibliotheken benötigt (optional Libraries)	

Tabelle 10: Ausgewählte Bibliotheken zur Anwendung der Finiten Elemente Methode im Vergleich.

## Projekt 2 CUDA

In diesem Projekt lag das Hauptaugenmerk auf der Programmierung auf der Grafikkarte mittels der Schnittstelle CUDA. Konkret kam CUDA 5.5 zum Einsatz.

N	RAM→RAM	RAM→VRAM	VRAM→VRAM	VRAM→RAM
$10^4$	0,03	0,6	0,74	0,6
$10^5$	0,3	1,7	9,1	0,7
$10^6$	1,5	2,2	28,2	1,1
$10^7$	2,4	2,4	38,2	1,4

Tabelle 11: Transferraten in GB/s nach Aufgabe 2a.

### Aufgabe 2.1 Getting started

Found 2 CUDA devices
=====
Information for GeForce GTX 960 (device 0):
Total global memory: 2092957696
Total const memory: 65536
Shared memory per block: 49152
Warp size: 32
Max threads per block: 1024
Max threads dimension: [ 1024, 1024, 64 ]
Max grid size: [ 2147483647, 65535, 65535 ]
-----
Information for GeForce GTX 560 Ti (device 1):
Total global memory: 2080768000
Total const memory: 65536
Shared memory per block: 49152
Warp size: 32
Max threads per block: 1024
Max threads dimension: [ 1024, 1024, 64 ]
Max grid size: [ 65535, 65535, 65535 ]

Listing 3. Ausgabe unseres Programms für die zwei CUDA-fähigen Grafikkarten in *i82sn02*.

In 3 ist die Ausgabe unseres Programms zu sehen. In den folgenden Aufgaben werden wir *device 0 (GeForce GTX 960)* verwenden.

### Aufgabe 2.2 Datentransferrate

Wie Tabelle 11 entnommen werden kann, Steigt die Transferrate vom RAM in den VRAM auf etwa 2,5 GB/s, während sich in der Gegenrichtung etwa 1,5GB/s erreichen lassen. Im VRAM konnten wir etwa 40 GB/s erreichen. Das Kopieren im RAM ist mit weniger als 2 GB/s deutlich langsamer und unterliegt starken Schwankungen.

Wie wir auch erwartet haben, bleiben die Transferraten

RAM→VRAM und VRAM→RAM unverändert. Da diese Daten Tabelle 11 entnommen werden können, sind sie in den Tabellen 12 und 13 nicht weiter aufgeführt. Da wir hier auf jeden Eintrag zusätzlich addieren etwas drauf addieren, sinkt die Transferrate im RAM. Mit steigender Blockgröße steigt die Leistung VRAM→VRAM anfangs fast linear, bis die Kurve bei Blockgröße 24 abflacht.

Die allgemein höhere Leistung mit größerer Problemgröße ist durch einen geringeren Anteil an Overhead zu erklären. Die SIMD-Register spielen eine wichtige Rolle. Durch diese wird ein Befehl gleichzeitig an viele der Rechenkerne geschickt. Dabei arbeiten diese den gleichen Befehl mit unterschiedlichen Daten ab. Bei der GTX 960 erfolgt dies mit 32 Befehlen parallel. Allerdings steht ein Teil der Einheiten still, wenn nicht genug parallele Befehle zur Verfügung stehen, da ein Warp immer nur von einem Block belegt werden kann. Daher sollte die Blockgröße immer in vielfachen von 32 gewählt werden.

Abschließend ist zu diesen Übertragungsraten zu sagen, dass die Aufgabe wesentlich aufwändiger sein muss, als zu inkrementieren, um die Übertragung an die GPU zu rechtfertigen, da in diesem Beispiel Hin- und Rückübertragung auf bzw. von der GPU länger dauert, als die Arbeit nur mit der CPU durchzuführen.

### Aufgabe 2.3 Gauß-Seidel-Verfahren

**2.3.a) Implementierung in CUDA.** Die Portierung des parallelisierten Gauß-Seidel-Verfahrens aus Aufgabe 1.4 verlief sehr geradlinig. Die zuvor parallelisierten inneren Schleifen – die Berechnung über alle schwarzen/weißen

Blockgröße	RAM→RAM	VRAM→VRAM
4	1,2	4,0
8	1,2	7,5
16	1,2	14,
24	1,2	19
32	1,2	22

Tabelle 12: Transferraten in GB/s nach Aufgabe 2b  $N = 10^6$  und verschiedenen Blockgrößen.

Blockgröße	RAM→RAM	VRAM→VRAM
4	2,0	4,3
8	2,0	8,3
16	2,0	16,2
24	2,0	22,3
32	2,0	30,1

Tabelle 13: Transferraten in GB/s nach Aufgabe 2b  $N = 10^7$  und verschiedenen Blockgrößen.

Felder – werden nun mittels entsprechender Kernel auf der GPU ausgeführt. Die Synchronisation ist damit nun implizit durch die Kernelaufufe – die nacheinander ausgeführt werden – gegeben.

Das eigentlich zweidimensional gegebene Problem haben wir als eindimensionales Problem an die GPU weitergegeben. Das heißt, wir haben als Größe des Problems den Vektor  $(n, 1, 1)^T$  verwendet (mit  $n$  wie aus Aufgabe 1.4). Da wir bei der Berechnung die zweidimensionale Struktur nicht explizit benötigen, lässt sich so ein potentieller Verschnitt bei der Aufteilung auf die *Warps* der GPU verkleinern.

Wie auch die CPU Variante haben wir zur Berechnung den Datentyp `double` verwendet. Damit der Compiler diesen auch tatsächlich verwendet, muss beim Kompilieren das Flag `-arch sm_13` mit angegeben werden (anderenfalls wird stattdessen mit `float` gearbeitet).

In Tabelle 14 haben wir die GPU-Implementierung mit der aus Projekt 1 verglichen. Für große Eingaben erreichen wir eine Beschleunigung von fast 9. Für kleine Eingaben ist die Laufzeit der GPU-Variante hingegen recht konstant. Wir führen das auf den Overhead zurück, der zur Ansteuerung der GPU nötig ist. Dieser amortisiert sich erst bei größeren Problemgrößen.

$l$	$T_{CPU}[s]$	$T_{GPU}[s]$	Beschleunigung $S[s]$
2	0,123	1,15	0,107
3	0,348	1,16	0,3
4	1,42	1,17	1,21
7	7,14	1,54	4,64
8	25,3	3,27	7,74
9	177	20,6	8,59

Tabelle 14: Laufzeit unserer GSV-Implementierung aus Aufgabe 1.4 mit 32 Kernen auf Rechner *i82sn07* verglichen mit unserer GPU-Implementierung auf dem Rechner *i82sn02*. Die Beschleunigung bezieht sich auf die GPU-Variante gegenüber der CPU-Variante ( $S = \frac{T_{CPU}}{T_{GPU}}$ ). Für kleine Eingaben ist die GPU-Variante deutlich langsamer als die CPU-Variante. Für große  $l$  hingegen erreicht sie eine Beschleunigung von bis zu  $\approx 9$ .

Ein schwer zu findender Bug verbirgt sich im Codeauszug 4, welcher im Gauß-Seidel-Verfahren zum erkennen der Abbruchbedingung verwendet wird. Da im

Aufruf von `cudaMemcpy` angegeben wird, dass nur genau 1 Byte kopiert werden soll, wird auch in der nicht initialisierten Variable `smallError` nur genau ein Bytes hineingeschrieben. Die restlichen Bytes sind un spezifiziert und können zu einem verfrühten Abbruch führen. Die Lösung ist eine Initialisierung mit 0 oder die Verwendung des Datentyps `char` anstatt `int` für die Variable `smallError`.

```
int smallError; // Datentyp muss char sein
cudaMemcpy(&smallError, smallError_d, 1,
           cudaMemcpyDeviceToHost);
if (smallError) break;
```

Listing 4. Ein schwer zu findender Bug im Gauß-Seidel-Verfahren, der sich nur manchmal bemerkbar machte.

### 2.3.b) Asynchrone Parallelisierungsmethoden.

- **Approximate Computing**

Unter Approximate Computing versteht man nach [17] und [15] eine Vorgehensweise, bei welcher auf eine hohe Genauigkeit verzichtet wird, um im Gegenzug an Geschwindigkeit und/oder Energieersparnisse in den Berechnungen zu gewinnen. Dies wird erreicht, indem beispielsweise Datentypen niedriger Genauigkeit genutzt werden. (Konkret etwa: anstatt `double` `float`, oder anstatt `float` nur `half float` verwenden.)

Dies ist unter Anderem dann sinnvoll, wenn die Eingangsdaten bereits gewisse Ungenauigkeiten aufweisen oder nur Schätzungen darstellen. Im Kontext des Praktikums, in welchem wir numerische Approximationen nutzen, stellt diese Technik einen Geschwindigkeitsgewinn mit vernachlässigbarer Ungenauigkeit dar, da die Natur von Approximationen bereits Ungenauigkeiten beinhaltet. Mehr dazu gegen Ende dieses Abschnitts.

- **Asynchronous Parallelization**

Um den Vorteil asynchroner Parallelisierung zu verdeutlichen, gehen wir zuvor näher auf die synchrone Variante ein. Als Beispiel soll ein evolutionärer Algorithmus dienen. Hier würde pro Thread jeweils eine Evolutionsstufe berechnet werden um anschließend auf allen anderen Threads dieser Iteration zu warten. Dies bedeutet für Threads, die ihre Aufgabe als erstes abschließen, dass eine Wartezeit entsteht, bis dann auch der letzte Thread zu einem Ergebnis gekommen ist. Asynchrone Parallelisierung eliminiert diese Wartezeiten, indem ein Thread einfach alle seine Iterationen durchlaufen kann ohne auf die Ergebnisse der anderen Threads zu warten (nach [20]). Dies bedeutet im Allgemeinen, dass die Threads die Aufgaben schneller abarbeiten können. Allerdings wird in diesem Kontext das Konstrukt von Generationen fallen gelassen. Dabei entstehende Ungenauigkeiten müssen in Kauf genommen werden. Weiter ist die Korrektheit des Ergebnisses nicht unbedingt trivial.

- **Relaxierte Parallelisierung**

Zu dieser Methode konnten wir nur wenig finden, das in unseren Kontext passt. Wir nehmen an, sie soll es nach der Raum- und Zeitdiskretisierung des stationären Problems erlauben, unabhängig

$l$	$T_{\text{double}}[s]$	$T_{\text{float}}[s]$	Beschleunigung $S[s]$
2	1,15	1,15	1,00
3	1,16	1,15	1,01
4	1,17	1,15	1,02
7	1,54	1,49	1,03
8	3,27	2,59	1,26
9	20,6	12,1	1,70

Tabelle 15: Laufzeiten unserer GSV-Implementierung, einmal mit Datentyp `double`, einmal mit `float`. Die Beschleunigung bei Verwendung von `float` gegenüber `double` wird für zunehmende  $l$  größer. Die Erwartung ist, dass für größere  $l$  schließlich eine Beschleunigung von 2 erreicht wird.

zwischen den entstandenen zeitlichen Unterteilungen Berechnungen durchführen zu können. Damit diese Unabhängigkeit zustande kommt, bedarf es vorher einer Relaxierung des Problems. Insgesamt erlaubt dies eine schnellere Ausführung der Aufgaben, da keine Abhängigkeiten zu vorherigen Resultaten existieren. Somit entfallen Wartezeiten auf Kosten der Genauigkeit des Endresultats (nach [12]).

Nach [16] sollte die Blockgröße – zumindest für die uns zur Verfügung stehende Architektur mit Warpgröße 32 – nach Möglichkeit immer als 32 gewählt werden. Dies erlaubt alle Recheneinheiten mit Threads zu belegen und somit eine optimale Auslastung. Weniger ist einer Verschwendung von Hardware gleichzustellen, da einzelne Recheneinheiten keinen Thread zugewiesen bekämen. Eine höhere Zahl bedeutet, dass sich die verfügbaren Recheneinheiten mehr Threads aufteilen müssen, was dazu führt, dass einige Threads erst nach Abarbeitung der vorherigen zur Ausführung kommen. Dies kann zu einer Zeitverschwendung führen, wenn diese Threads keine sinnvoll Arbeit verrichten, und sollte daher vermieden werden.

Wir haben uns dazu entschieden, die approximative Methode anzuwenden. Begonnen mit dem Compilerflag `-use-fast-math` – welches im Kontext von Relaxierung ebenfalls zu Gunsten der Berechnungszeit weniger Rechengenauigkeit garantiert – welches uns jedoch in der Laufzeit keinen Unterschied bescherte. Wir führen dies darauf zurück, dass wir keine aufwändigeren Mathematikoperationen wie Kosinus oder Sinus berechnen lassen.

Die andere, bereits genannte mögliche Umsetzung, besteht aus der Verwendung von weniger genauen Datentypen. Für unser konkret wäre das hier `float` (32 Bit) anstatt `double` (64 Bit). Bei vergleichbarer Anzahl an Iterationen konnten wir, wie Tabelle 15 zu entnehmen ist, für große Eingaben tatsächlich fast die Hälfte an Zeit einsparen. Wir führen das darauf zurück, dass GPUs eher zur Berechnung von Fließkommazahlen mit geringer Genauigkeit optimiert sind (da für Grafik oft ausreichend) und daher hierfür auch mehr Recheneinheiten zur Verfügung stehen.

Der nächste Schritt wäre, mittels `half float` noch mehr an Genauigkeit – zugunsten der Geschwindigkeit – aufzugeben. Dass dies funktionieren könnte, wir auch vom Blogeintrag [11] bestätigt. Demnach ist auch hier nochmals eine Verdopplung zu erwarten. Getestet haben wir es nicht, da wir denken, dass für unsere Anwendung die damit verbundene Ungenauigkeit möglicherweise zu

groß wird. Ferner ist der Datentyp `half float` erst ab CUDA 7.5 verfügbar, wohingegen wir mit CUDA 5.5 arbeiten.

**2.3.c) Eignung für andere Architekturen.** Wir haben *Approximate Computing* eingesetzt, um Rechenzeit auf Kosten der Genauigkeit einzusparen. Diese Technik sollte in modernen CPUs die Geschwindigkeit kaum beeinflussen. Nach unserem Kenntnisstand haben CPUs keine speziellen *Floating Point Units* (FPU), um beispielsweise `float` und `double` getrennt zu verarbeiten. Stattdessen wird mit der gleichen Hardware in höherer Genauigkeit (etwa 80 Bit, Hardware abhängig) gerechnet. Diese These konnten wir mit unserem Gauß-Seidel-Verfahren aus 1.4 bestätigen, da dieses mit dem Datentyp `float` (anstatt `double`) keine bessere Laufzeit aufwies.

Ein Unterschied wäre möglicherweise bei sehr großen Datenmengen feststellbar. Da bei `double` das doppelte an Information in den Speicher und Caches geladen werden muss, wäre hier ein Leistungseinbruch denkbar. Dies wäre eher im Bereich von Single Multi-Core CPUs angesiedelt, da Many-Core- und MIC-Architekturen durch mehrere Speicheranbindungen und größeren Cache nicht so schnell neue Daten anfordern müssten.

## Aufgabe 2.4 LU-Zerlegung

Mit Hilfe der LU-Zerlegung zerlegen wir  $A$  in zwei Matrizen  $L$  und  $U$ , sodass  $L \cdot U = A$  mit  $L$  ist untere, und  $U$  ist obere Dreiecksmatrix. Um auch weiterhin mit dünn besetzten Matrizen arbeiten zu können, verwenden wir eine unvollständige Zerlegung (ILU), d.h.  $L \cdot U \approx A$  mit dünn besetzten  $L$  und  $U$ .

**2.4.a) Eignung.** Algorithmus 1 scheint die bessere Wahl hinsichtlich der Stabilität zu sein, da eine ILU-Zerlegung nach Gauss (Algorithmus 2) ohne geeignete Pivotwahl nach [8] schnell unter Stabilitätsproblemen leiden kann. Da in Algorithmus 2 keine spezielle Pivotwahl getroffen wird, stellt dies ein Problem für entsprechende Elemente der Diagonale dar. Die schlechte Stabilität entsteht dadurch, dass nachdem wir  $l_{jj}$  berechnet haben, wir genau diesen Wert im Nenner eines Bruchs nutzen. Ist dieser Wert hinreichend nah an 0, ohne 0 zu sein, entstehen in der Berechnung von  $l_{ij}$  ungewollt große Zahlen.

Algorithmus 1 lässt sich sehr gut parallelisieren, da innerhalb einer Iterierten  $m$  alle Einträge unabhängig von einander berechnet werden können. Zwischen den Iterierten ist jedoch eine Synchronisation nötig, da jede Iterierte die Ergebnisse der vorherigen Iterierten benötigt. Für den Datenaustausch zwischen zwei iterierten werden lediglich zwei Puffer benötigt, einer hält stets die aktuellen Werte und wird beschrieben, während der andere die Ergebnisse der letzten Iterierten bereithält. Die Puffer können dann während der Ausführung nach jeder Iteration ausgetauscht werden.

Die Parallelisierbarkeit von Algorithmus 2 hingegen schätzen wir als schlecht ein. Ähnlich dem Gauß-Seidel-Verfahren aus Projekt 1 beinhaltet er Abhängigkeiten zwischen den einzelnen Einträgen, die während einer Iteration  $j$  berechnet werden. Je innerer Iteration (über  $i$ ) können jedoch aufgrund der Abhängigkeiten maximal 2 Werte

parallel berechnet werden, hierfür lohnt sich eine Parallelisierung unserer Einschätzung nach nicht. Eine Lösung wäre hier eine asynchrone Herangehensweise wie in der vorherigen Aufgabe beschrieben, die jedoch erneut die Frage nach dem Erhalt der Korrektheit des Verfahrens aufwerfen würde.

Die Matrizen  $L$  und  $U$  sind dünn besetzt, daher erscheint es sinnvoll, die Daten komprimiert zu speichern. Aufgrund der Struktur von  $A$  – und damit auch der von  $L$  und  $U$ , wie wir in der nächsten Teilaufgabe aufzeigen werden – gibt es nur insgesamt 5 Diagonalen, die Einträge  $\neq 0$  enthalten können. Wir verwenden daher der Einfachheit halber Arrays der Größe  $5 \cdot N$ , da diese auf jeden Fall genügend Platz zum Speichern bereitstellen. Für jede Zeile einer Matrix verwenden wir demnach 5 Einträge im Array. Im Falle von  $l = 2, d = 3, n = 9$  sieht die Belegung  $B$  der Matrizen  $A, L$  und  $U$  exemplarisch so aus:

$$B = \begin{pmatrix} * & * & 0 & * & 0 & 0 & 0 & 0 & 0 \\ * & * & * & 0 & * & 0 & 0 & 0 & 0 \\ 0 & * & * & 0 & 0 & * & 0 & 0 & 0 \\ * & 0 & 0 & * & * & 0 & * & 0 & 0 \\ 0 & * & 0 & * & * & * & 0 & * & 0 \\ 0 & 0 & * & 0 & * & * & 0 & 0 & * \\ 0 & 0 & 0 & * & 0 & 0 & * & * & 0 \\ 0 & 0 & 0 & 0 & * & 0 & * & * & * \\ 0 & 0 & 0 & 0 & 0 & * & 0 & * & * \end{pmatrix} \quad (14)$$

Wobei Einträge mit  $*$  bedeuten, dass nur an diesen Stellen Einträge  $\neq 0$  sein können. Rot eingefärbte 0en verweisen auf Einträge, die immer 0 sind, aber in der von uns gewählten Speichermethodik dennoch Platz einnehmen. Insgesamt gibt es davon  $4 \cdot d$  Stück (im Beispiel liegen 8 davon außerhalb der Matrix und sind daher nicht sichtbar). Wegen  $n = d \cdot d$  ist der Verschnitt für große  $n$  zunehmend vernachlässigbar, sodass eine platzsparendere Speicherung den zusätzlichen Programmieraufwand unserer Meinung nach nicht rechtfertigen würde.

Bei Ausführung der Algorithmen ist uns aufgefallen, dass  $L \cdot U$  tatsächlich eine gute Approximation für  $A$  ist, allerdings nur für Einträge in denen  $A$  selbst nicht 0 ist. Bei  $l = 2, n = 9$  erhielten wir beispielsweise

$$L \cdot U \approx \begin{pmatrix} 4 & -1 & 0 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 4 & -1 & 0.25 & -1 & 0 & 0 & 0 & 0 \\ 0 & -1 & 4 & 0 & 0.27 & -1 & 0 & 0 & 0 \\ -1 & 0.25 & 0 & 4 & -1 & 0 & -1 & 0 & 0 \\ 0 & -1 & 0.27 & -1 & 4 & -1 & 0.27 & -1 & 0 \\ 0 & 0 & -1 & 0 & -1 & 4 & 0 & 0.29 & -1 \\ 0 & 0 & 0 & -1 & 0.27 & 0 & 4 & -1 & 0 \\ 0 & 0 & 0 & 0 & -1 & 0.29 & -1 & 4 & -1 \\ 0 & 0 & 0 & 0 & 0 & -1 & 0 & -1 & 4 \end{pmatrix}$$

als Ergebnis, wobei wir Abweichungen von  $A$  (also 0) mit rot markiert haben. Die Frage die sich uns hier gestellt hat, war, inwiefern  $L \cdot U$  dennoch als Approximation von  $B$  aus der nächsten Aufgabe geeignet sind.

**2.4.b) Implementierung.** Bei der Implementierung von **Algorithmus 2** ist uns aufgefallen, dass Einträge, die in  $A$  0 sind, auch in  $L$  auf 0 gesetzt werden. Ferner gilt  $U = L^T$  und  $A$  ist symmetrisch. Daraus ergibt sich für die Einträge von  $A, L$  und  $U$ :

$$\forall i, j : a_{i,j} = 0 \Rightarrow l_{i,j} = l_{j,i} = u_{i,j} = u_{j,i} = 0 \quad (15)$$

Somit eignet sich die Speichermethodik aus der vorherigen Teilaufgabe auch für die Matrizen  $L$  und  $U$  aus **Algorithmus 2**. Beim Implementieren ist uns ferner aufgefallen,

dass  $L$  und  $U$  nicht mit 0 initialisiert sein sollten, da ansonsten Werte  $NaN$  in den Ergebnismatrizen auftauchen. Mit der Einheitsmatrix als Startwert von  $L$  und  $U$  leistet der Algorithmus das Gewünschte.

Für **Algorithmus 1** wählen wir nun als Indexmenge  $S_U$  genau die Einträge, die nach **Algorithmus 2** in  $U$  ungleich 0 sein können. Damit ist auch die Validität unserer gewählten Speichermethodik für diesen Algorithmus garantiert, da auch hier  $L = U^T$  gilt und

$$\forall (i, j) \notin S_U : u_{i,j} = l_{j,i} = 0 \quad (16)$$

Geschwindigkeitstechnisch profitiert **Algorithmus 2** nur unwesentlich von der parallelen Architektur, da aufgrund der Abhängigkeiten maximal drei Elemente gleichzeitig berechnet werden können. **Algorithmus 1** hingegen profitiert sehr von der parallelen Architektur der GPU, da innerhalb einer Iteration alle Einträge komplett unabhängig von einander berechnet werden können. Zudem ist die tatsächliche Anzahl benötigter Schritte in der Regel weit unter  $n$ . Für ein Abbruchkriterium mit  $\varepsilon_{ILU} = 10^{-10}$  und Problemgröße  $n = 261.121$  wurden gerade einmal 19 Iterationen benötigt.

**2.4.c) Eignung von OpenMP.** Für **Algorithmus 1**: Für kleine  $n$  würde eine Parallelisierung in OpenMP – also auf der CPU – möglicherweise Sinn machen, aufgrund des Mehraufwandes der für die GPU-Ausführung erforderlich ist. Für große  $n$  hingegen erwarten wir, dass die CUDA-Implementierung einen Performance-Vorteil gegenüber der CPU-Implementierung hat. Dies schließen wir vor allem daraus, dass sich der Algorithmus sehr gut für die Grafikkarte parallelisieren lässt, da innerhalb einer Iteration Einträge unabhängig von einander sind.

## Aufgabe 2.5 Vorkonditionierung

**2.5.a) Kombination.** Selbst mit  $l = 9$  war es uns mit unseren bisherigen Komponenten nicht möglich, die gewünschte Genauigkeit von  $\epsilon_i \leq 10^{-5}$  zu erreichen. Unabhängig von der gewählten Größe der  $\varepsilon$  für die Abbruchkriterien lag unser bestes Ergebnis bei einem lokalen Fehler von  $\epsilon_i = 1,257 \times 10^{-5} > 10^{-5}$ . Wie wir in Projekt 1 gesehen haben, hängt der Fehler bei diesem Problem stark von der Gitterauflösung ab. Es ist daher naheliegend, es einmal mit  $l = 10$  zu versuchen. Bisher war uns dies aufgrund unserer Implementierung des Gauß-Seidel-Verfahrens nicht möglich, da wir hier eine Historie der Größe  $d$  für alle Einträge von  $u$  verwendeten. Damit ergab sich für  $l = 10$  ein Speicherbedarf von  $(2^{10} - 1)^3 \cdot 8 \text{ Bytes} \approx 8 \text{ GB}$  allein für die Historie von  $u$ . Wie in Aufgabe 2.1 zu sehen, haben wir jedoch nur  $\approx 2 \text{ GB}$  Grafikspeicher zur Verfügung.

Um das Problem zu lösen wollen wir die Historie von  $u$  vermeiden. Benutzt haben wir sie, um in der Ausgabe des GSV garantieren zu können, dass alle Einträge des ausgegebenen  $u$  aus der gleichen Iterierten stammen. Wenn wir nun zulassen, dass Einträge aus  $u$  aus neueren Iterierten stammen, als die Iterierte, in der die Abbruchbedingung zum ersten mal erfüllt wurde, können wir mit einem  $u$  der Größe  $(2^{10} - 1)^2 \cdot 8 \text{ Bytes} \approx 8 \text{ MB}$  auskommen. Diese Herangehensweise scheint uns zulässig, da das Gauß-Seidel-Verfahren monoton gegen die perfekte Lösung zu konvergieren scheint, neuere Einträge von  $u$

also höchstens eine bessere Genauigkeit ausweisen, jedoch keine schlechtere. Aus diesem Grund könnte diese Vereinfachung gar zu einem genaueren Gesamtergebnis führen. Wir würden sie daher nicht zu den Verfahren des *Approximate Computing* aus Aufgabe 2.3 zählen. Gleichwohl erwarten wir durch diese Lösung auch einen Geschwindigkeitszuwachs, dadurch begründet, dass der zugriffene Speicher kleiner ist, und somit eher in vorhandene Caches passen sollte.

Mit  $l = 10$  war es uns schließlich möglich, eine Lösung mit einem maximalen lokalen Fehler von  $\epsilon_i = 3,25 \times 10^{-6} < 10^{-5}$  (mit  $\epsilon_{cg} = \epsilon_{ILU} = \epsilon_{GSV} = 10^{-6}$  für die Abbruchkriterien) zu berechnen. Es ist anzumerken, dass wir hierfür die Blockgröße von 32 (der Warpgröße) auf  $8 \cdot 32$  erhöhen mussten, um überhaupt sinnvolle Ausgaben zu erhalten. Den Grund hierfür konnten wir leider nicht ausmachen, denn theoretisch sollte eine Grid-Größe von maximal

$$g_n = \left\lfloor \frac{n + \text{blocksize} - 1}{\text{blocksize}} \right\rfloor$$

$$= \left\lfloor \frac{4.092.529 + 32 - 1}{32} \right\rfloor$$

$$= 127.892$$

(eindimensional) von der *GeForce GTX 960* unterstützt werden (vgl. Listing 3 aus Aufgabe 1.1,  $g_{max} = 2.147.483.647$ ).

Da wir unserer Implementierung aus Projekt 1 nicht mit  $l = 10$  testen können (Grund ist die genannte Historie), vergleichen wir im folgenden die Ergebnisse für maximal  $l = 9$ . Für die Abbruchkriterien wählen wir  $\epsilon_{cg} = \epsilon_{ILU} = \epsilon_{GSV} = 10^{-6}$ . Die Ergebnisse zeigen wir in Tabelle 16.

$l$	Impl.	It.	$T[s]$	$T_{iteration}[s]$	Fehler $\epsilon_i$
7	CPU	243	1,7	$7 \times 10^{-3}$	$2,01 \times 10^{-4}$
	GPU a)	91	1,83	$2,01 \times 10^{-2}$	$2,01 \times 10^{-4}$
	GPU c)	91	1,72	$1,89 \times 10^{-2}$	$2,01 \times 10^{-4}$
8	CPU	483	2	$4,14 \times 10^{-3}$	$5,02 \times 10^{-5}$
	GPU a)	153	7,04	$4,60 \times 10^{-2}$	$5,21 \times 10^{-5}$
	GPU c)	153	6,17	$4,03 \times 10^{-2}$	$5,21 \times 10^{-5}$
9	CPU	961	2,5	$2,6 \times 10^{-3}$	$1,26 \times 10^{-5}$
	GPU a)	285	71,0	$2,49 \times 10^{-1}$	$1,31 \times 10^{-5}$
	GPU c)	285	64,0	$2,24 \times 10^{-1}$	$1,31 \times 10^{-5}$

Tabelle 16: Die verschiedenen Implementierungen des CG-Verfahrens im Vergleich: die parallelisierte CPU Variante aus Aufgabe 1.6, die aus Aufgabe 2.5 a) mit Berechnung sowohl auf der GPU, als auch der CPU, sowie die Variante aus Aufgabenteil c), die nur auf der GPU arbeitet. Mit Iterationen ist die Anzahl der Iterationen des CG-Verfahrens gemeint. Es ist festzuhalten, dass die CPU-Variante etwa 60mal schneller ist, als die GPU Implementierungen. Getestet wurde auf *i82sn07* für die CPU, und auf *i82sn02* für die GPU. Jeweils  $l = 9$  mit Abbruchkriterien  $\epsilon = 10^{-6}$ .

Die Laufzeiten sowie die Beschleunigung gegenüber unserer Lösung aus Aufgabe 1.6 können Tabelle 17 entnommen werden. Sie zeigt, dass das vorkonditionierte-Verfahren, entgegen unserer Erwartungen, langsamer ist, als die ursprüngliche, auf der CPU implementierte Variante. Wir führen das auf die relativ teure Berechnung von  $Br$  zurück, bei der zweimal eine Berechnung mittels Gauß-Seidel-Verfahren angestoßen wird.

$l$	$S_{CPU \rightarrow GPU_a}[s]$	$S_{GPU_a \rightarrow GPU_c}[s]$
7	0,929	1,06
8	0,284	1,14
9	0,0352	1,11

Tabelle 17: Beschleunigung  $S_{CPU \rightarrow GPU_a}$  der GPU-Variante aus a) gegenüber der CPU Variante aus Projekt 1, sowie Beschleunigung  $S_{GPU_a \rightarrow GPU_c}$  der GPU Variante aus b) gegenüber der aus a). Basierend auf den Messungen in Tabelle 16.

Für eine Visualisierung des berechneten Ergebnisses verweisen wir auf Abbildung 3 aus Aufgabe 1.5. Für größere  $l$  approximiert die berechnete Lösung die analytische noch besser, einen weiteren Unterschied gibt es nicht.

**2.5.b) Genauigkeit.** Insgesamt haben wir für die zu berechnende Genauigkeit drei Parameter: die in den jeweiligen Abbruchkriterien verwendeten  $\epsilon_{cg}, \epsilon_{ILU}, \epsilon_{GSV}$ . In Tabelle 18 haben wir den lokalen Fehler in Abhängigkeit von verschiedenen  $\epsilon$  abgetragen.

Wir schließen aus den Messwerten, dass  $\epsilon_{cg}$  für den Fehler des Ergebnisses am wichtigsten ist. Das macht Sinn in dem Zusammenhang, als dass die ILU-Zerlegung, und damit auch die GSV-Berechnung, hier nur Näherungen sind und daher nicht genau berechnet zu werden brauchen. Gleichzeitig lässt sich aber auch feststellen, dass das gesamte Verfahren mit insgesamt weniger Iterationen auskommt, wenn auch für die LU- und die GSV-Berechnung eine höhere Genauigkeit angestrebt wird. Insbesondere, da die Berechnung der LU-Zerlegung – verglichen mit den restlichen Berechnungen – sehr schnell ist (muss nur einmal zu Beginn durchgeführt werden), macht es Sinn,  $\epsilon_{ILU}$  grundsätzlich klein zu wählen.

Für ein genaueres Abwägen zwischen Berechnungszeit, Genauigkeit und Abbruchkriterien müssten sehr viel mehr Daten gesammelt werden. Während eine ungenauere GSV-Berechnung für sich schneller durchzuführen ist, scheint sie dazu zu führen, dass mehr Iterationen, und damit mehr GSV-Berechnungen insgesamt, durchzuführen sind. Optimale Werte für  $\epsilon$  könnten iterativ bestimmt werden.

$\epsilon_{cg}$	$\epsilon_{ILU}$	$\epsilon_{GSV}$	Fehler $\epsilon_i$	$\Delta \epsilon_i$
$10^{-3}$	$10^{-3}$	$10^{-3}$	$2,20 \times 10^{-4}$	0
$10^{-6}$	$10^{-3}$	$10^{-3}$	$5,14 \times 10^{-5}$	$-1,69 \times 10^{-4}$
$10^{-3}$	$10^{-6}$	$10^{-3}$	$1,97 \times 10^{-4}$	$-2,30 \times 10^{-5}$
$10^{-3}$	$10^{-3}$	$10^{-6}$	$2,14 \times 10^{-4}$	$-6,02 \times 10^{-7}$
$10^{-12}$	$10^{-3}$	$10^{-3}$	$5,02 \times 10^{-5}$	$-1,70 \times 10^{-4}$
$10^{-12}$	$10^{-12}$	$10^{-12}$	$5,02 \times 10^{-5}$	$-1,70 \times 10^{-4}$

Tabelle 18: Der maximale lokale Fehler für verschiedene Belegungen von  $\epsilon_{cg}, \epsilon_{ILU}, \epsilon_{GSV}$ . Getestet mit  $l = 8$  auf Rechner *i82sn02*. Es ist anzumerken, dass zur Berechnung der letzten Zeile nur etwa die Hälfte an CG-Iterationen benötigt wurde (278), als in der Zeile zuvor (551).

**2.5.c) Verfahrenskomponenten.** Durch die Kombination des CG-Verfahrens aus Projekt 1 (OpenMP) mit dem Löser für  $Br$  aus diesem Projekt (CUDA) ergibt sich eine Aufteilung der Berechnungsschritte sowohl auf die CPU als auch die GPU. Wir halten dieses Vorgehen für höchst fragwürdig, da

- 1) Es dazu führt, dass Daten ständig zwischen Hauptspeicher und Grafikspeicher ausgetauscht werden müssen
- 2) Aufgrund der Abhängigkeit der Berechnungsschritte die CPU und GPU nicht gleichzeitig sinnvolle Arbeit verrichten können
- 3) Wir in Aufgabe 2.3 bereits gesehen haben, dass die GPU manche Aufgaben sehr viel schneller ausführen kann, als die CPU. Dies erwarten wir auch hier, da es sich bei den noch auf der CPU ausgeführten Teilen vorwiegend um Vektoroperationen handelt, die sich sehr gut für die GPU parallelisieren lassen.

Aus diesen Gründen haben wir uns dafür entschieden, das CG-Verfahren vollständig auf der GPU zu berechnen. Das heißt, die Daten werden die ganze Zeit über im Grafikspeicher gehalten und dort nur von Kernen manipuliert, die vom Host-Code aufgerufen werden.

Für die Berechnung der Skalarprodukte  $p_m^T(Ap_m)$  und  $r_m^T(Br_m)$  (genauer: das Aufsummieren über die Elementweisen Produkte) haben wir uns der in [10] vorgestellten parallelen Reduktion bedient. Wir erwarten damit eine bessere Geschwindigkeit als bei der Verwendung von *Atomics*, da letztere zu einer teuren Synchronisation zwischen Threads führen.

Aus Tabelle 17 ergeben sich Beschleunigungen von bis zu 1,14 für  $l = 8$  von der reinen GPU-Variante, gegenüber deren, die sowohl auf der GPU als auch auf der CPU rechnet. Der Geschwindigkeitsunterschied ist geringer, als wir erwartet hätten. Wir führen das darauf zurück, dass das Lösen von  $Br$  mittels zwei Aufrufen des Gauß-Seidel-Verfahrens vergleichsweise rechenaufwändig ist, und daher die Speichertransfers weniger ins Gewicht fallen. Pro Iteration müssen zwei Speicher-Kopieoperationen, sowie zwei GSV-Berechnungen durchgeführt werden.

## Aufgabe 2.6 Lattice-Boltzmann-Methode (LBM)

**2.6.a) Würfelgröße.** Nach unseren Ergebnissen aus Aufgabe 2.1 steht uns auf der *GeForce GTX 960* ein globaler Speicher von 2.092.957.696 Bytes = 1.996MB zur Verfügung. Die Daten für unseren Würfel dürfen demnach nicht mehr als diesen Speicherplatz benötigen.

Im Grafikspeicher müssen die Arrays `rawdata1`, `rawdata2` sowie `u_0` gehalten werden. Bei den Arrays `gridI` und `gridO` handelt es sich lediglich um eine Indexierung der Knoten des Gitters, die nicht explizit gespeichert werden müssen.

Bei `rawdata1` und `rawdata2` handelt es sich um Arrays der Größe  $max_x \cdot max_y \cdot max_z \cdot 19$  mit Datentyp `double`. Für diese werden somit je

$$\begin{aligned} M(\text{rawdata1}) &= M(\text{rawdata2}) \\ &= max_x \cdot max_y \cdot max_z \cdot 19 \cdot 8 \end{aligned}$$

Bytes benötigt. Im Gegensatz hierzu ist `u_0` im Wesentlichen ein zweidimensionales Array der Größe  $max_x \cdot max_y$ , ebenfalls vom Typ `double`. Für dieses ergibt sich somit ein Speicherbedarf von

$$M(u_0) = max_x \cdot max_y \cdot 8$$

Bytes.

Insgesamt ergibt sich somit ein Speicherbedarf auf der GPU von

$$\begin{aligned} M &= M(\text{rawdata1}) + M(\text{rawdata2}) + M(u_0) \\ &= 2 \cdot max_x \cdot max_y \cdot max_z \cdot 19 \cdot 8 + max_x \cdot max_y \cdot 8 \\ &= 8 \cdot max_x \cdot max_y \cdot (38 \cdot max_z + 1) \end{aligned}$$

Bytes, wobei  $M$  nicht größer als der verfügbare globale Speicher sein darf, also

$$M \leq 2.092.957.696$$

Bei Würfeln sind alle Kanten gleich lang, somit gilt

$$max_x = max_y = max_z$$

und der Speicherbedarf vereinfacht sich zu

$$M = 8 \cdot max_x^2 \cdot (38 \cdot max_x + 1)$$

in Bytes. Die maximale Seitenlänge, die diese Bedingung erfüllt ist  $max_x = max_y = max_z = 190$  mit einem Speicherbedarf von  $M = 2.085.424.800$  Bytes (ermittelt mittels dem Programm *GeoGebra*).

**2.6.b) Große Würfel.** Bei Würfeln die größer sind als  $max_x = max_y = max_z = 190$  passen die Daten nicht alle gleichzeitig in den Grafikspeicher, sie müssten demnach während der Berechnung zwischen Haupt- und Grafikspeicher ausgetauscht werden. Da diese Kopieoperationen vergleichsweise langsam sind, ist mit einer sehr starken Verschlechterung der Performanz zu rechnen.

**Unser Fazit.** Im Rahmen des Praktikums wurden mehrere Themenbereiche aus der Informatik sowie der Mathematik behandelt.

Das erste Projekt lies uns erste Erfahrungen mit OpenMP sammeln, indem die nicht deterministische Reihenfolge der Threadausführung gezeigt wurde. Daraufhin wurden Testtools (Intel Thread Checker und OpenMP Profiler) eingeführt, damit wir unsere Programme auf Fehler untersuchen konnten. Nach diesen ersten Schritten sollten wir uns Gedanken über Maße der parallelen Ausführung machen, welches uns zu mehreren quantitativen Maßzahlen im Kontext von Parallelrechnern geleitet hat. Zeitgleich sollten wir uns andere Architekturen und Beschleuniger ansehen und über ihre Vor- und Nachteile diskutieren. Des weiteren wurden typische Fehler, wie etwa Verklemmungen und Wettlaufsituationen, betrachtet und beschrieben, unter welchen Bedingungen diese eintreten können.

Als nächstes sollte dann ein erstes Verfahren, das Gauß-Seidel-Verfahren, sequentiell implementiert werden, um es anschließend zu parallelisieren mithilfe des angeeigneten Wissen der vorherigen Aufgaben. Zusätzlich war es noch notwendig, eine geeignete Parallelisierungsmethodik zu finden, um eine Beschleunigung trotz Datenabhängigkeiten zu erreichen.

Daraufhin wurde unser parallelisiertes Verfahren zur Lösung einer partiellen Differentialgleichung eingesetzt. Hier wurde die Methode der Finiten Differenzen eingesetzt, um das Problem in uniforme Teile zu zerlegen. Diese Zerlegung nimmt einen Parameter entgegen um so die Feinheit der Unterteilung festzulegen. Dies erlaubte uns Unterschiede in benötigter Rechenzeit und maximalem Berechnungsfehler zu untersuchen.

Als letzter Aspekt für das erste Projekt wurde aus mehreren Krylow-Unterraumverfahren das CG-Verfahren aus-  
gesucht und implementiert. Dieses sollte das gleiche Problem wie auch schon vorher das Gauß-Seidel-Verfahren lösen (Poisson-Gleichung), aber mit der Erwartung dass es schneller zum gewünschten Resultat kommt, was wir auch tatsächlich beobachten konnten.

Das zweite Projekt hatte das Hauptaugenmerk nicht mehr auf der CPU als Hauptrecheneinheit, sondern der GPU, welche wir mit Hilfe von CUDA programmieren konnten.

Erste Aufgaben waren das Auslesen der Architekturinformation von den verfügbaren Beschleuniger und die verschiedenen Datentransferraten zu ermitteln.

Die vorherigen Programme wurden dann auch noch für eine Ausführung auf der GPU angepasst. Der daraus entstandene Geschwindigkeitszuwachs, verglichen zur CPU-Ausführung, wurde dann nochmals durch eine breit ausgelegte Literaturrecherche verbessert. Im Allgemeinen wird versucht, an einigen Stellen etwas an Genauigkeit einzusparen um somit eine erheblich höhere Geschwindigkeit zu erreichen. Wir haben eine Technik ausgewählt und diese auf unseren Programmen angewendet. Diese Resultate ließen dann Rückschlüsse über die interne Struktur der CPU und GPU zu. Zeitgleich hat dies unsere Ausführungszeit bei hoher Auflösung sehr stark verbessert.

Des weiteren wurde das Konzept der Vorkonditionierung anhand von zwei gegebenen Algorithmen eingeführt. Diese sollten kurz aus Sicht der Mathematik analysiert werden. Die Analyse lieferte uns Informationen zu Vor- und Nachteilen in der Parallelisierbarkeit und Stabilität.

Mit allen Bausteinen des Praktikums sollte dann zuletzt ein vollständiges Programm entstehen, welches die Poisson-Gleichung aus dem ersten Projekt löst, unter Einhaltung eines gegebenen maximalen Fehlers. Durch die vielen einzelnen Stellen, an welchen der tolerierte Fehler der verschiedenen Verfahren angepasst werden konnte, war es uns möglich ein, schnelles Programm zu entwickeln, welches uns Einsichten in den Einfluss der verschiedenen Teile des Programm geliefert hat. Zu guter Letzt durften wir die Erfahrung machen, dass es hier tatsächlich sinnvoll ist, alle Komponenten auf der GPU auszuführen. Auch wenn der dabei beobachtete Geschwindigkeitszuwachs unter unseren Erwartungen lag, was wir auf den Aufwand der einzelnen Berechnungsschritte zurückgeführt haben.

Das Praktikum hat uns vieles über numerische Aspekte gelehrt, als auch welche Techniken zur Parallelisierung von Programmen genutzt werden können. Insbesondere sind wir nun in der Lage, auf der CPU mittels OpenMP, als auch auf der Grafikkarte mittels CUDA, Programme zu parallelisieren und damit (hoffentlich) zu beschleunigen.

## Literatur

- [1] *Deal.II*. <https://www.dealii.org/>
- [2] *Feel++*. <http://www.feelpp.org/>
- [3] *HiFlow3*. <http://www.hiflow3.org/>
- [4] Krylow-Unterraum-Verfahren. <https://de.wikipedia.org/wiki/Krylow-Unterraum-Verfahren>
- [5] *Libmesh*. <http://libmesh.github.io/>
- [6] *MFEM*. <http://mfem.org/>
- [7] BAUER, Lars: *Eingebettete Systeme I*
- [8] BENZI, Michele: Preconditioning Techniques for Large Linear Systems: A Survey. In: *Journal of Computational Physics* 182 (2002), nov, Nr. 2, 418–477. <http://dx.doi.org/10.1006/jcph.2002.7176>. – DOI 10.1006/jcph.2002.7176
- [9] BRAESS, Dietrich: *Finite Elemente : Theorie, schnelle Löser und Anwendungen in der Elastizitätstheorie*. (2007)
- [10] HARRIS, Mark: *Optimizing Parallel Reduction in CUDA*. [http://developer.download.nvidia.com/compute/cuda/1.1-Beta/x86\\_website/projects/reduction/doc/reduction.pdf](http://developer.download.nvidia.com/compute/cuda/1.1-Beta/x86_website/projects/reduction/doc/reduction.pdf),
- [11] HARRIS, Mark: *Mixed-Precision Programming with CUDA 8*. <https://devblogs.nvidia.com/parallelforall/mixed-precision-programming-cuda-8/>, 2016
- [12] IACONO, Francesca: *High-Order Methods for Convection-Dominated Nonlinear Problems Using Multilevel Techniques*
- [13] INTEL: *Intel Xeon Phi Produktreihe*. <http://www.intel.de/content/www/de/de/processors/xeon/xeon-phi-detail.html>,
- [14] KARL, Prof. Dr. W.: *Vorlesung Rechnerstrukturen*. (2015)
- [15] MITTAL, Sparsh: *A Survey of Techniques for Approximate Computing*
- [16] NVIDIA: *CUDA Toolkit Documentation*. <https://developer.nvidia.com/cuda-toolkit>,
- [17] PEKHIMENKO, Gennady ; KOUTRA, Danai ; QIAN, Kun: *Approximate Computing: Application Analysis and Hardware Design*.
- [18] PFAFFE, Philip: *Software Engineering für moderne parallele Plattformen*. (2016)
- [19] WEISS, Daniel: *Numerische Mathematik für die Fachrichtungen Informatik und Ingenieurwesen*. (2015)
- [20] WESSING, Simon ; RUDOLPH, Günter ; MENGES, Dino A.: *Comparing Asynchronous and Synchronous Parallelization of the SMS-EMOA*