Karlsruher Institut für Technologie

Projekt 2

Arbeiten mit CUDA

Fabian Miltenberger, Sébastien Thill, Thore Mehr | 07.02.2017

LEHRSTUHL FÜR RECHNERARCHITEKTUR UND PARALLELVERARBEITUNG (ITEC)

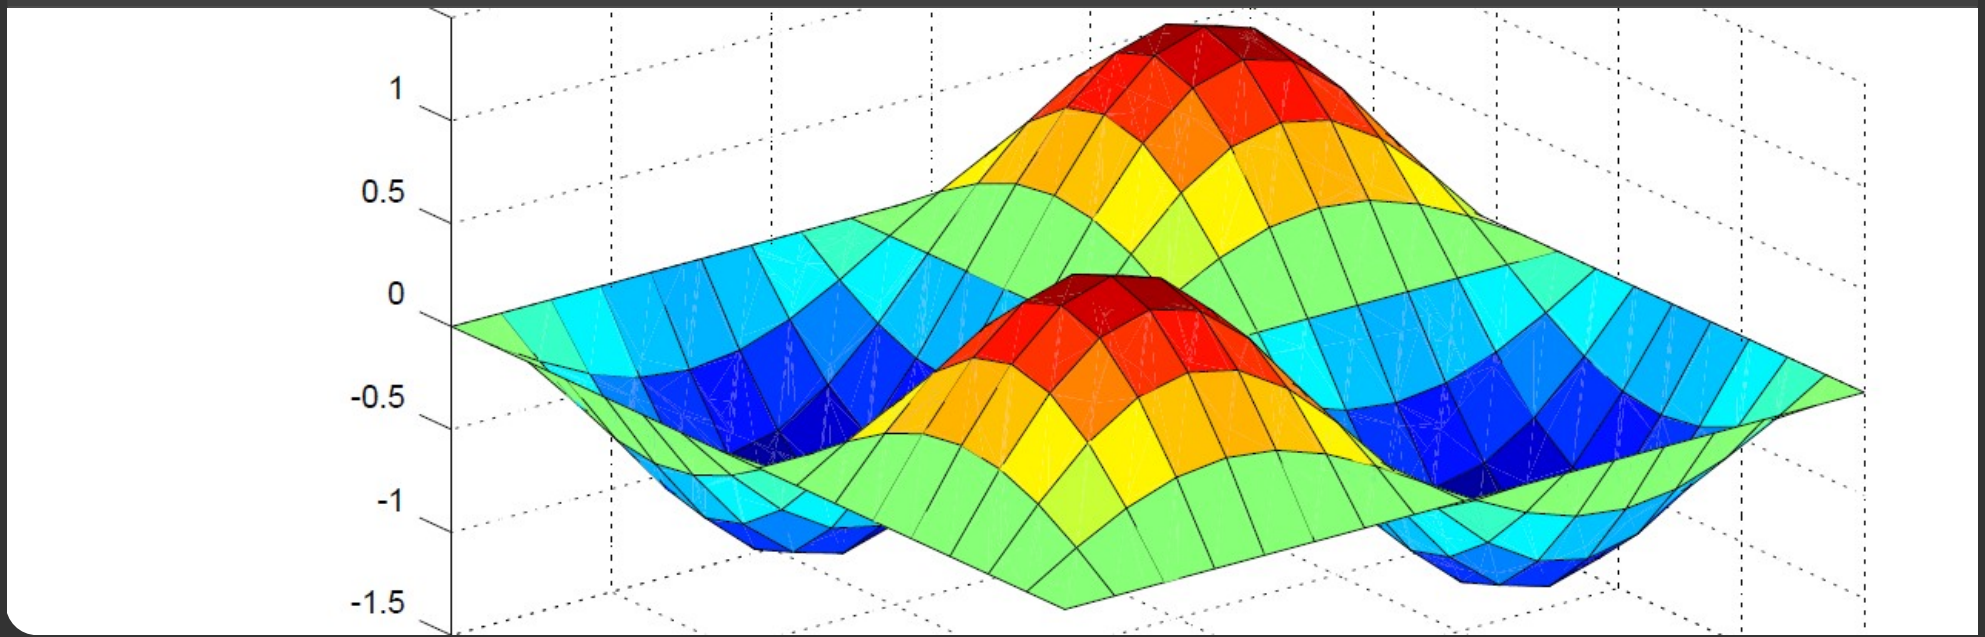

Gliederung

Struktur nach Aufgaben, aber mit grobem Einblick in unsere Vorgehensweise

Aufgabe 1 – Getting started

```
Information for GeForce GTX 960 (device 0):
Total global memory: 2092957696 ≈ 2 GB
Total const memory: 65536 ≈ 64 KB
Shared memory per block: 49152 ≈ 48 KB
Warp size: 32
Max threads per block: 1024
Max threads dimension: [ 1024, 1024, 64 ]
Max grid size: [ 2147483647, 65535, 65535 ]
```

→ Damit haben wir gearbeitet

Aufgabe 2 – Datentransferraten

Aufgabe 3 – Gauß-Seidel-Verfahren

Implementierung: Sehr geradlinig, Synchronisation durch Kernelaufrufe

Beschleunigung gegenüber CPU (32 Kerne):

l	$T_{CPU}[s]$	$T_{GPU}[s]$	Beschleunigung $S[s]$
2	0,123	1,15	0,107
3	0,348	1,16	0,3
4	1,42	1,17	1,21
7	7,14	1,54	4,64
8	25,3	3,27	7,74
9	177	20,6	8,59

Aufgabe 3 – Asynchrone Parallelisierung

- **Approximate Computing**
  auf eine hohe Genauigkeit verzichtet wird, um im Gegenzug an Geschwindigkeit und/oder Energieersparnisse in den Berechnungen zu gewinnen. Dies wird erreicht, indem beispielsweise Datentypen niedriger Genauigkeit genutzt werden. (Konkret etwa: anstatt `double` `float`, oder anstatt `float` nur `half float` verwenden.)
  Dies ist unter Anderem dann sinnvoll, wenn die Eingangsdaten bereits gewisse Ungenauigkeiten aufweisen oder nur Schätzungen darstellen. Im Kontext des Praktikums, in welchem wir numerische Approximationen nutzen, stellt diese Technik einen Geschwindigkeitsgewinn mit vernachlässigbarer Ungenauigkeit dar, da die Natur von Approximationen bereits Ungenauigkeiten beinhaltet. Mehr dazu gegen Ende dieses Abschnitts.
- **Asynchronous Parallelization**
  Um den Vorteil asynchroner Parallelisierung zu verdeutlichen, gehen wir zuvor näher auf die synchrone Variante ein. Als Beispiel soll ein

Aufgabe 3 – Approximate Computing

Keine Verbesserung durch Flag `-use-fast-math`

Beschleunigung bei `float` anstatt `double`:

l	$T_{\texttt{double}}[s]$	$T_{\texttt{float}}[s]$	Beschleunigung $S[s]$
2	1,15	1,15	1,00
3	1,16	1,15	1,01
4	1,17	1,15	1,02
7	1,54	1,49	1,03
8	3,27	2,59	1,26
9	20,6	12,1	1,70

Weitere Beschleunigung für `half` möglich? (ab CUDA 7.7)

Aufgabe 3 – Programmierfehler

Dieser Code bricht manchmal zu früh ab:

```
...
int smallErr;
cudaMemcpy(&smallErr, smallErr_d, 1, DeviceToHost);
if (smallError) break;
...
```

Aufgabe 3 – Programmierfehler

Dieser Code bricht manchmal zu früh ab:

```
...
int smallErr;
cudaMemcpy(&smallErr, smallErr_d, 1, DeviceToHost);
if (smallError) break;
...
```

→`smallErr` hat zu großen Datentyp, muss entweder initialisiert werden, oder von Datentyp `char` sein

Aufgabe 3 – Weitere Architekturen

Wir haben **Approximate Computing** eingesetzt, um Rechenzeit auf Kosten der Genauigkeit einzusparen. Diese Technik sollte in modernen CPUs die Geschwindigkeit kaum beeinflussen. Nach unserem Kenntnisstand haben CPUs keine speziellen **Floating Point Units** (FPU), um beispielsweise `float` und `double` getrennt zu verarbeiten. Stattdessen wird mit der gleichen Hardware in höherer Genauigkeit (etwa 80 Bit, Hardware abhängig) gerechnet. Diese These konnten wir mit unserem Gauß-Seidel-Verfahren aus **??** bestätigen, da dieses mit dem Datentyp `float` (anstatt `double`) keine bessere Laufzeit aufwies.
Ein Unterschied wäre möglicherweise bei sehr großen Datenmengen feststellbar. Da bei `double` das doppelte an Information in den Speicher und Caches geladen werden muss, wäre hier ein Leistungseinbruch denkbar. Dies wäre eher im Bereich von Single Multi-Core CPUs angesiedelt, da Many-Core- und MIC-Architekturen durch mehrere Speicheranbindungen und größeren Cache nicht so schnell neue Daten anfordern müssten.

Aufgabe 4 – ILU-Zerlegung

Gesucht: Dreiecksmatrizen L, U, sodass

$$L \cdot U \approx A$$

Algorithmus 2

- Starke Abhängigkeit der Einträge
  $\rightarrow$Schlecht parallelisierbar

Algorithmus 1

- Einträge komplett unabhängig
  $\rightarrow$Sehr gut parallelisierbar
- Pufferung zwischen Iterierten
- Approximativ

Aufgabe 4 – Speichermethodik

Nach Algorithmus 2: $a_{ij} = 0 \Rightarrow l_{ij} = 0$ und $U = L^T$ (S_U entsprechend)
Belegung von L, U und A:

$$\mathcal{B} = \begin{pmatrix} * & * & 0 & * & 0 & 0 & 0 & 0 & 0 \\ * & * & * & 0 & * & 0 & 0 & 0 & 0 \\ 0 & * & * & 0 & 0 & * & 0 & 0 & 0 \\ * & 0 & 0 & * & * & 0 & * & 0 & 0 \\ 0 & * & 0 & * & * & * & 0 & * & 0 \\ 0 & 0 & * & 0 & * & * & 0 & 0 & * \\ 0 & 0 & 0 & * & 0 & 0 & * & * & 0 \\ 0 & 0 & 0 & 0 & * & 0 & * & * & * \\ 0 & 0 & 0 & 0 & 0 & * & 0 & * & * \end{pmatrix}$$

$\rightarrow$Speicherung möglich als Array der Größe $5n$
Speicherverschnitt in $\mathcal{O}(\sqrt{n})$

Aufgabe 4 – Ergebnis

Stark abweichende Einträge in $L \cdot U$:

$$L \cdot U \approx \begin{pmatrix} 4 & -1 & 0 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 4 & -1 & 0.25 & -1 & 0 & 0 & 0 & 0 \\ 0 & -1 & 4 & 0 & 0.27 & -1 & 0 & 0 & 0 \\ -1 & 0.25 & 0 & 4 & -1 & 0 & -1 & 0 & 0 \\ 0 & -1 & 0.27 & -1 & 4 & -1 & 0.27 & -1 & 0 \\ 0 & 0 & -1 & 0 & -1 & 4 & 0 & 0.29 & -1 \\ 0 & 0 & 0 & -1 & 0.27 & 0 & 4 & -1 & 0 \\ 0 & 0 & 0 & 0 & -1 & 0.29 & -1 & 4 & -1 \\ 0 & 0 & 0 & 0 & 0 & -1 & 0 & -1 & 4 \end{pmatrix} \overset{!}{\approx} A$$

Für unsere folgende Vorkonditionierung *hoffentlich* vernachlässigbar

Aufgabe 4 – OpenMP

Für Algorithmus 1: Für kleine n würde eine Parallelisierung in OpenMP – also auf der CPU – möglicherweise Sinn machen, aufgrund des Mehraufwandes der für die GPU-Ausführung erforderlich ist. Für große n hingegen erwarten wir, dass die CUDA-Implementierung einen Performance-Vorteil gegenüber der CPU-Implementierung hat. Dies schließen wir vor allem daraus, dass sich der Algorithmus sehr gut für die Grafikkarte parallelisieren lässt, da innerhalb einer Iteration Einträge unabhängig von einander sind.

Aufgabe 5 – CG-Verfahren

Idee: Anstatt $B \approx A^{-1}$ berechnen wir $LU = A$ durch unvollständige Zerlegung
Nun können wir $Br = p$ bzw. $r = LAp$ berechnen durch:

$$L\hat{p} = r, Up = \hat{p}$$

In unserem Fall: mittels GSV

Aufgabe 5 – Poisson-Problem

Gefordert: $\epsilon_i \leq 10^{-5}$

Unsere Implementierung mit $l = 9$: $\epsilon_{max} = 1,257 \times 10^{-5}$

Aufgabe 5 – Poisson-Problem

Gefordert: $\epsilon_i \leq 10^{-5}$
Unsere Implementierung mit $l = 9$: $\epsilon_{max} = 1,257 \times 10^{-5}$

Intention: $l = 10$ setzen
Würde $(2^{10} - 1)^3 \cdot 8$ Bytes $\approx$8 GB für Historie von u benötigen
$\rightarrow$Speicherproblem

Aufgabe 5 – Poisson-Problem

Gefordert: $\epsilon_i \leq 10^{-5}$
Unsere Implementierung mit $l = 9$: $\epsilon_{max} = 1,257 \times 10^{-5}$

Intention: $l = 10$ setzen
Würde $(2^{10} - 1)^3 \cdot 8$ Bytes $\approx$8 GB für Historie von u benötigen
$\rightarrow$Speicherproblem

Lösung: Auf Historie verzichten
Speicherbedarf für u: $(2^{10} - 1)^2 \cdot 8$ Bytes $\approx$8 MB
Problem: Auswirkung unklar, aber funktioniert (Approximate Computing?)
Fehler jetzt: $\epsilon_{max} = 3,25 \times 10^{-6}$
Größere *blocksize* nötig?

Aufgabe 5 – Vergleich

l	Impl.	Iterationen	$T[s]$	$T_{iteration}[s]$	Fehler ϵ_i
7	CPU	243	$1,7$	7×10^{-3}	$2,01 \times 10^{-4}$
	GPU	91	$1,83$	$2,01 \times 10^{-2}$	$2,01 \times 10^{-4}$
8	CPU	483	2	$4,14 \times 10^{-3}$	$5,02 \times 10^{-5}$
	GPU	153	$7,04$	$4,60 \times 10^{-2}$	$5,21 \times 10^{-5}$
9	CPU	961	$2,5$	$2,6 \times 10^{-3}$	$1,26 \times 10^{-5}$
	GPU	285	$71,0$	$2,49 \times 10^{-1}$	$1,31 \times 10^{-5}$

$\rightarrow$ Weniger Iterationen, aber **mehr Zeitaufwand**

Aufgabe 5 – Poisson-Problem

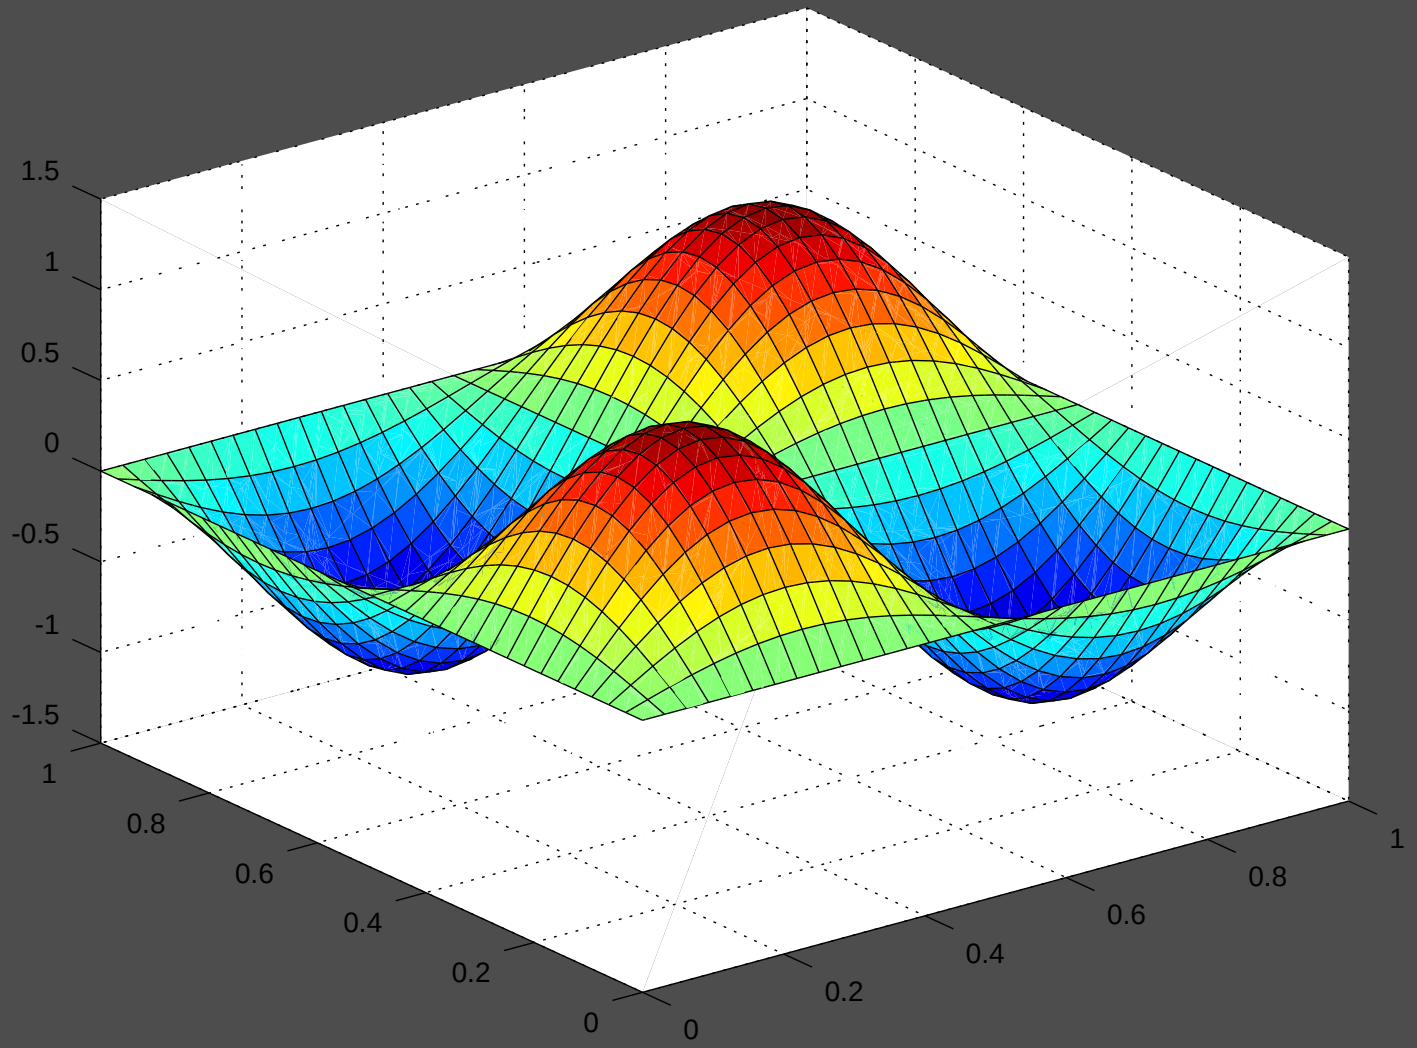

Aufgabe 5 – Genauigkeit

Stellschrauben: $\varepsilon_{cg}, \varepsilon_{ILU}, \varepsilon_{GSV}$

Auswirkung auf den Fehler:

ε_{cg}	ε_{ILU}	ε_{GSV}	Fehler ϵ_{max}	$\Delta\epsilon_{max}$
10^{-3}	10^{-3}	10^{-3}	$2,20 \times 10^{-4}$	0
10^{-6}	10^{-3}	10^{-3}	$5,14 \times 10^{-5}$	$-1,69 \times 10^{-4}$
10^{-3}	10^{-6}	10^{-3}	$1,97 \times 10^{-4}$	$-2,30 \times 10^{-5}$
10^{-3}	10^{-3}	10^{-6}	$2,14 \times 10^{-4}$	$-6,02 \times 10^{-7}$
10^{-12}	10^{-3}	10^{-3}	$5,02 \times 10^{-5}$	$-1,70 \times 10^{-4}$
10^{-12}	10^{-12}	10^{-12}	$5,02 \times 10^{-5}$	$-1,70 \times 10^{-4}$

$\rightarrow \varepsilon_{cg}$ hat größte Relevant; naheliegend, da Rest Approximation

Aufgabe 5 – Beschleuniger

Bisher: Alles (außer Berechnung von *Br* (2×GSV)) auf CPU per OpenMP

Wenig sinnvoll, da:

1. Overhead durch Datenaustausch
2. Keine gleichzeitige Auslastung
3. GPU vermutlich schneller in den CPU-Aufgaben (Vektoroperationen)

Aufgabe 5 – Beschleunigung

l	$S_{CPU \to GPU_a}[s]$	$S_{GPU_a \to GPU_c}[s]$
7	0,929	1,06
8	0,284	1,14
9	0,0352	1,11

Vorteil geringer als gedacht...

Br teuerster Berechnungsschritt

Aufgabe 5 – Skalarprodukt auf der GPU

Möglich mittels `atomic`-Operationen, aber nicht optimal

Bessere Lösung: *Reduction* (wie auch in OpenMP)

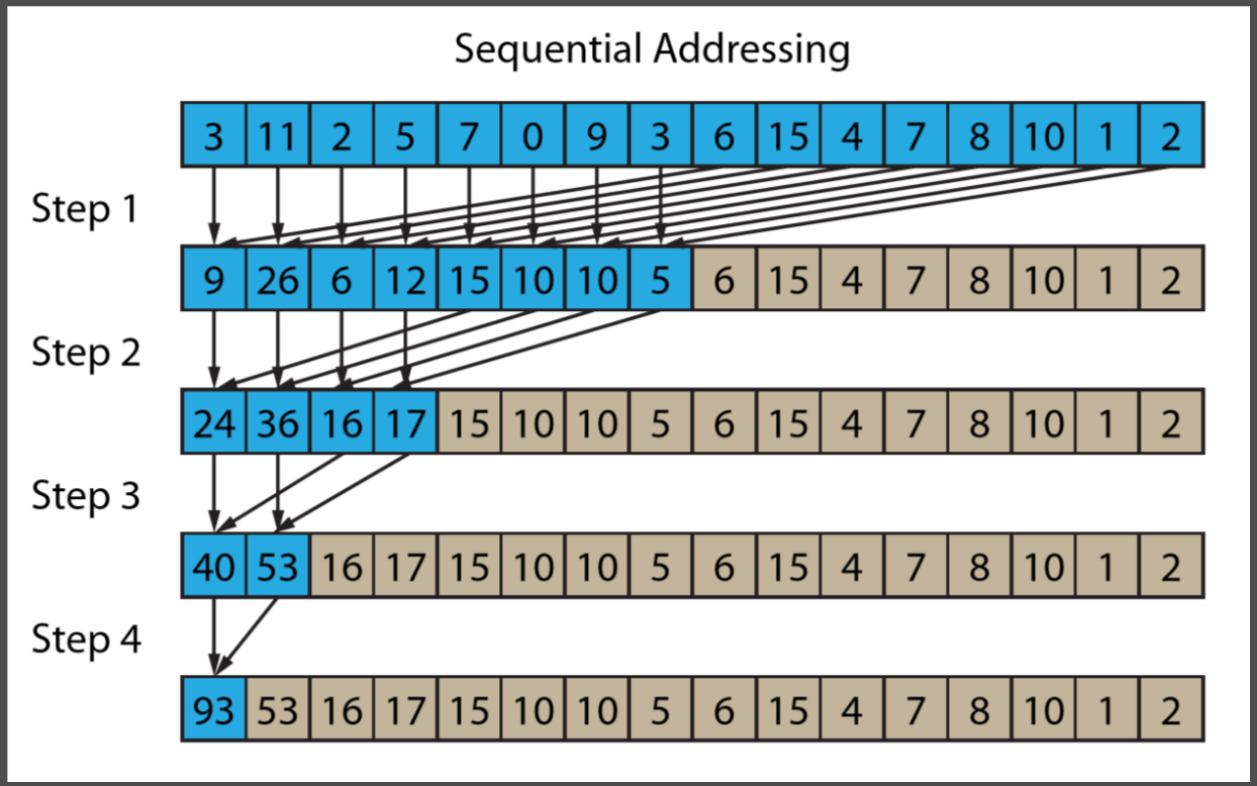

Aufgabe 6 – Lattice-Blotzmann-Methode

Maximale Größe des Gitters?
Verfügbarer Speicherplatz auf der GPU $\approx$ 2 GB

Aufgabe 6 – Lattice-Blotzmann-Methode

Maximale Größe des Gitters?
Verfügbarer Speicherplatz auf der GPU $\approx$ 2 GB

Speicherbedarf für `rawdata1`, `rawdata2` und `u_0`:

$$\begin{aligned} M(\texttt{rawdata1}) &= M(\texttt{rawdata2}) \\ &= max_x \cdot max_y \cdot max_z \cdot 19 \cdot 8 \text{ Bytes} \\ M(\texttt{u\_0}) &= max_x \cdot max_y \cdot 8 \text{ Bytes} \end{aligned}$$

Aufgabe 6 – Lattice-Blotzmann-Methode

Maximale Größe des Gitters?
Verfügbarer Speicherplatz auf der GPU $\approx$ 2 GB

Speicherbedarf für `rawdata1`, `rawdata2` und `u_0`:

$$\begin{aligned} M(\texttt{rawdata1}) &= M(\texttt{rawdata2}) \\ &= max_x \cdot max_y \cdot max_z \cdot 19 \cdot 8 \text{ Bytes} \\ M(\texttt{u\_0}) &= max_x \cdot max_y \cdot 8 \text{ Bytes} \end{aligned}$$

Bedingung: $M(\texttt{rawdata1}) + M(\texttt{rawdata2}) + M(\texttt{u\_0}) \leq 2.092.957.696$
Lösung: $max_x = max_y = max_z = 190$

Aufgabe 6 – Große Würfel

Würfel noch größer $\rightarrow$ passt nicht mehr in VRAM

Fazit

Mit *CUDA* lässt es sich parallelisieren.